

ПРАВИТЕЛЬСТВО РОССИЙСКОЙ ФЕДЕРАЦИИ
ФГАОУ ВО НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ
«ВЫСШАЯ ШКОЛА ЭКОНОМИКИ»

Факультет гуманитарных наук
Образовательная программа «Компьютерная лингвистика»

ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА

Исследовательский проект на тему:

**Автоматическое распознавание, перевод и анализ древнегерманских рунических
текстов**

Выполнил студент:

группы #МКЛНГ241, 2 курса магистратуры

Перфильев Антон Юрьевич

Принял руководитель ВКР:

Макаров Илья Андреевич

PhD

Факультет компьютерных наук НИУ ВШЭ

Содержание

Аннотация	5
Введение	6
1 Обзор литературы	10
1.1 Трансформерные архитектуры в распознавании рукописного текста	10
1.2 TrOCR и адаптация к историческим документам	11
1.3 Мультимодальные модели в OCR исторических документов	11
1.4 Детекторы объектов для эпиграфики	12
1.5 Рунические надписи: цифровая рунология и состояние корпуса	13
1.5.1 Корпуса и инфраструктура	13
1.5.2 Традиция 3D-сканирования	13
1.5.3 Состояние цифровой рунологии и единичные нейросетевые работы . .	14
1.6 Методологические аналогии из смежных малоресурсных доменов	14
1.7 Идентифицированные лакуны и позиционирование работы	15
2 Лингвистические и материальные основания задачи	15
2.1 Рунические письменные системы: графемный инвентарь и история	15
2.1.1 Старший футарк	16
2.1.2 Младший футарк	17
2.1.3 Англосаксонский футарк	18
2.1.4 Следствия для архитектурных решений	18
2.2 Физическая деградация носителей как задача компьютерного зрения	19
2.2.1 Типология носителей и механизмы деградации	20
2.2.2 Спектральная неоднозначность	20
2.3 Инфраструктура цифровых рунических корпусов	21
2.3.1 Samnordisk runtextdatabas (Rundata)	21
2.3.2 Альтернативные базы и корпусные ресурсы	21
2.3.3 Архитектурные ограничения для машинного обучения	22
2.3.4 Стратегия интеграции в ML-конвейер	23
2.4 Конвенции транслитерации и формализация эпиграфической неопределённости	24
2.4.1 Множественность стандартов транслитерации	24
2.4.2 Эпиграфическая неопределённость как проблема ground truth	25

2.4.3	Формализация неопределённости для машинного обучения	26
2.4.4	Принятые в работе соглашения	27
3	Эмпирическая база и формирование корпуса	28
3.1	Стратегия формирования данных: обучение на синтетике, оценка на реальном золотом стандарте	29
3.2	Золотой стандарт (gold set)	30
3.3	Синтетический корпус	32
3.3.1	Лексическая основа: извлечение слов из реальных баз	32
3.3.2	Рендеринг рунической строки	33
3.3.3	Выбор парадигмы синтеза и модальности обусловливания	33
3.3.4	Конвейер SD3 + ControlNet Canny: параметры	35
3.4	Предобработка изображений и протокол разбиения	37
3.4.1	Предобработка изображений	37
3.4.2	Протокол разбиения и контроль утечки	38
4	Методология и архитектура	38
4.1	Постановка задачи и общая схема конвейера	39
4.2	Baseline 1: TrOCR с адаптацией LoRA	40
4.3	Baseline 2: мультимодальная модель Qwen-VL с адаптацией QLoRA	41
4.4	Демонстрационный модуль автоматического перевода	42
4.5	Протокол обучения и инфраструктура	44
5	Экспериментальная часть	44
5.1	Протокол оценки и метрики	44
5.2	Конфигурации моделей и состав данных	45
5.3	Качество моделей без адаптации	47
5.4	Результаты после дообучения на синтетике	48
5.5	Анализ ошибок	49
5.6	Соотнесение с гипотезой и границы применимости	50
6	Обсуждение, ограничения и направления дальнейшей работы	51
6.1	Обсуждение результатов	51
6.2	Ограничения исследования	52
6.3	Направления дальнейшей работы	53

Заключение	54
Список литературы	56
А Пример секции аппендикса	63

Аннотация

Работа посвящена автоматическому распознаванию древнегерманских (скандинавских) рунических надписей по фотографиям в условиях критически малого объёма реальных данных. Объект — памятники рунической эпиграфики на различных материальных носителях. Предмет — методы и алгоритмы автоматического распознавания рунических знаков на изображениях в малоресурсном домене. Цель — разработать и экспериментально оценить сквозную систему распознавания рунической транслитерации. Методология сочетает критический обзор и типологизацию архитектур, формирование данных и обучение моделей с переносом обучения. Принят принцип разделения сигналов: обучение ведётся исключительно на синтетическом корпусе изображений, генерируемом латентной диффузией (Stable Diffusion 3) с пространственным обуславливанием ControlNet по карте границ Canny, лексика которого извлечена из базы Rundata и сводки Gamla runor; оценка — на реальном «золотом» множестве из 113 строк с экспертной транслитерацией. Целевой выход — латинская строка транслитерации в конвенции Rundata, что устраняет необходимость расширения токенизатора. Сопоставлены специализированный распознаватель TrOCR (адаптация LoRA) и мультимодальные модели семейства Qwen-VL (QLoRA). Основной результат: без адаптации задача недоступна ($CER > 100 \%$); дообучение на синтетикекратно улучшает качество, лучшая конфигурация Qwen2.5-VL-7B достигает $CER 54,27 \%$ на реальных данных. Установлено, что доминирующим источником ошибки выступает синтетически-реальный доменный сдвиг (+32...+42 п. п.), а не ёмкость модели, и что мультимодальный зрительно-языковой прайор переносится на реальные носители лучше специализированного OCR, который при хорошей подгонке к синтетике коллапсирует. Вклад работы — первая воспроизводимая базовая линия распознавания для скандинавского рунического материала и количественная характеристика доменного разрыва.

Ключевые слова

Рунические надписи, оптическое распознавание текста, OCR, TrOCR, мультимодальные модели, синтетические данные, малоресурсное обучение, доменный сдвиг, цифровая эпиграфика, древнескандинавский язык

Введение

Древнегерманские рунические надписи охватывают период приблизительно со II по XV в. н. э., локализованы преимущественно на территории Скандинавии, Британских островов и континентальной Европы и зафиксированы на камне, металле, кости и дереве. Несмотря на обширный научный опыт их изучения, значительная часть рунологической работы по-прежнему опирается на ручную транскрипцию специалистом, владеющим палеографической и археологической компетенциями. Это создает трудности при оцифровке музейных коллекций, ограничивает воспроизводимость отдельных чтений и затрудняет доступ исследовательского сообщества к первичному материалу. В настоящей работе рунические надписи рассматриваются как объект автоматической обработки методами компьютерного зрения и обработки естественного языка.

Актуальность исследования определяется тремя обстоятельствами. В 2019–2025 гг. методы машинного обучения закрепились в обработке древних текстов: модели Pythia, Ithaca и Aeneas установили стандарт для восстановления и атрибуции древнегреческих и латинских эпиграфических текстов [1, 2, 3], а обзор в журнале *Computational Linguistics* систематизировал направление как самостоятельную ветвь вычислительной филологии [4]. Также сохраняется разрыв между объёмом рунического корпуса и доступными цифровыми возможностями: значительная часть скандинавских архивов оцифрована неполно, а экспертная транскрипция остаётся трудоёмкой [5]. Помимо этого, трансформерные архитектуры оптического распознавания типа TrOCR демонстрируют устойчивое преимущество над свёрточно-рекуррентными конвейерами на задачах исторического OCR [6], а методы параметрически эффективной адаптации (PEFT, в частности LoRA) позволяют переносить крупные предобученные модели в малоресурсные домены при ограниченных вычислительных бюджетах [7].

Степень разработанности проблемы характеризуется выраженной асимметрией между эпиграфическими традициями. Для греко-латинской традиции сложился методологический стандарт линейки Pythia – Ithaca – Aeneas [1, 2, 3]. Клинописная эпиграфика обработана как на уровне распознавания и транслитерации знаков [8], так и на уровне восстановления повреждённых фрагментов [9]. Конвейер DeepScribe демонстрирует применимость модульных систем компьютерного зрения к корпусу эламской клинописи [10]. Для китайской традиции цзягувэнь разработаны двухступенчатые системы детекции и классификации знаков [11] и генеративные подходы к дешифровке средствами диффузионных моделей [12]. Близкая по форме древнетюркская руниформа получила конвейеры синтетической генерации данных с трёхмерным моделированием носителя [13], нейросетевые модели для орхонских надпи-

сей [14] и базовые архитектуры распознавания [15]. Схема «детекция + классификация» также применима к греческим надписям на византийских печатях [16]. Вместе с тем на момент первой половины 2026 г. в индексируемых рецензируемых изданиях отсутствуют публикации, в которых трансформерные OCR-архитектуры применялись бы к корпусу скандинавских рунических надписей. Тем самым формируется локализованная исследовательская лакуна, заполнение которой составляет содержание настоящей работы.

Объектом исследования выступают памятники древнегерманской рунической эпиграфики на различных типах материальных носителей. **Предметом исследования** являются методы и алгоритмы автоматического распознавания рунических знаков на фотографических изображениях в условиях малоресурсного домена.

Цель работы – разработать и экспериментально оценить систему автоматического распознавания и лингвистического анализа древнегерманских рунических надписей по фотографическим изображениям с применением современных методов глубокого обучения и синтетической аугментации данных. Центральный исследовательский вопрос: в какой мере комбинация контекстных трансформерных архитектур и контролируемой синтетической генерации данных позволяет преодолеть малоресурсность рунического материала и приблизить долю посимвольных ошибок (Character Error Rate, CER) к условному порогу практической применимости – 20 %?

Под лингвистическим анализом в работе понимается демонстрационный модуль автоматического перевода распознанной транслитерации на современный язык, реализованный на основе смежного исследования [17, 18]. Разработка переводческой модели не входит в число задач настоящей работы и привлекается лишь для демонстрации сквозной работы конвейера «распознавание – перевод».

Для достижения цели необходимо решить следующие **задачи**:

- 1 провести систематический обзор современных подходов компьютерного зрения и машинного обучения к распознаванию (OCR/HTR) исторических и эпиграфических памятников;
- 2 сформировать эмпирическую базу: собрать и систематизировать корпус фотографий реальных рунических надписей из открытых архивов и разработать алгоритм синтеза искусственных изображений для расширения обучающей выборки;
- 3 спроектировать и реализовать конвейер предобработки изображений, адаптированный к физической и спектральной деградации эпиграфических носителей;

- 4 Реализовать и сравнить два подхода к сквозному (end-to-end) распознаванию транслитерации: дообучение специализированной OCR-модели TrOCR и адаптацию мультимодальной vision-language-модели семейства Qwen-VL с использованием метода параметрически эффективного дообучения LoRA на синтетическом корпусе данных;
- 5 продемонстрировать сквозную работу конвейера, подключив к распознанной транслитерации демонстрационный модуль автоматического перевода на современный язык (на основе смежной работы [17]);
- 6 провести качественный анализ типологии ошибок и определить границы практической применимости системы.

Методология сочетает теоретические, эмпирические и экспериментальные процедуры: аналитический обзор литературы и типологизацию архитектур; отбор, очистку и аннотацию изображений из открытых архивов и формирование контролируемого синтетического корпуса; обучение и дообучение моделей с использованием transfer learning, сравнение архитектурных конфигураций. Ввиду отсутствия унифицированного изобразительно-текстового корпуса рунических надписей обучение моделей ведётся на синтетическом корпусе, а оценка – на вручную выверенном реальном корпусе изображений ограниченного объёма, что изолирует и количественно характеризует синтетически-реальный доменный сдвиг.

Эмпирическую базу составляют четыре источника: Samnordisk runtextdatabas Уппсальского университета, предоставляющая транскрипции и нормализованные тексты; поисковая служба Söktjänsten Runor Шведского управления по охране культурного наследия (Riksantikvarieämbetet), агрегирующая метаданные около семи тысяч надписей; открытые архивы скандинавских музеев (Historiska museet, Danske Runeindskrifter, Runearkivet Музея истории культуры Университета Осло); синтетический корпус собственной генерации с моделью физической деградации носителя.

Научная новизна работы состоит в следующем: представлена первая систематическая адаптация трансформерных OCR-архитектур к скандинавскому руническому материалу; предложена методология контролируемой синтетической генерации рунических изображений с явным моделированием деградации носителя; выполнено сравнительное сопоставление OCR-архитектуры TrOCR и мультимодальной vision-language-модели (Qwen-VL), адаптированных параметрически эффективным методом (LoRA) на синтетическом корпусе, в рамках единого протокола оценки; разработана унифицированная схема аннотации, совместимая с задачами компьютерного зрения и допускающая повторное использование.

Теоретическая значимость определяется первым систематическим тестированием трансформерных OCR-архитектур на корпусе скандинавских рунических надписей, что расширяет эмпирическую базу обзорных исследований по машинному обучению для древних языков, а также вкладом в методологию переноса техник синтетического обучения между эпиграфическими доменами. **Практическая ценность** автоматического распознавания и предварительного перевода рунических надписей определяется не замещением эксперта-рунолога, а расширением доступа к текстам за пределами узкой специализации исследователя. Полевые археологические работы, музейная каталогизация и сравнительно-исторические исследования германских древностей регулярно сталкиваются с надписями, прочтение которых требует участия рунолога, тогда как археологи, антропологи, археозоологи и реставраторы, работающие с тем же материалом, как правило, не владеют руническим письмом и не имеют возможности постоянно привлекать профильного специалиста. Инструмент, дающий по фотографии надписи предварительную транслитерацию и черновой перевод, обеспечивает быструю первичную ориентацию в содержании источника, что особенно значимо в полевой ситуации, когда уточнение контекста необходимо немедленно, а опубликованные издания обновляются медленно и неравномерно. Аналогичную функцию такой инструмент выполняет в музейной и образовательной среде, делая рунические памятники доступными широкой аудитории без специальной филологической подготовки. Тем не менее, важно отметить, что автоматический распознаватель не претендует на окончательную научную интерпретацию и предполагает последующую экспертную проверку.

Структура работы следует логике от обзора и теоретических оснований к экспериментальной верификации. Первая глава содержит критический обзор литературы по машинному обучению для древних языков и эпиграфики. Вторая глава излагает рунологические, лингвистические и архитектурно-вычислительные основания работы. Третья глава описывает эмпирическую базу, процедуры аннотации и предобработки изображений. Четвёртая глава представляет методологию и архитектуру разработанного конвейера – две end-to-end-конфигурации (дообучение TrOCR и адаптацию мультимодальной модели Qwen-VL средствами LoRA), а также демонстрационный модуль автоматического перевода транслитерации. Пятая глава содержит экспериментальную часть: протокол оценки, основные результаты и типологический анализ ошибок. Заключение подводит итоги и формулирует перспективы исследования. Работу завершает список использованной литературы.

1 Обзор литературы

Глава представляет критический обзор работ 2019–2026 гг. по автоматическому распознаванию (OCR/HTR) исторических текстов на твёрдых носителях средствами глубокого обучения. Цель обзора – очертить состояние разработанности темы и локализовать незаполненную нишу. Центральный результат, к которому подводит анализ, состоит в следующем: по состоянию на 2026 г. в рецензируемой литературе отсутствуют публикации, применяющие современные нейросетевые архитектуры (CNN, ViT, TrOCR, мультимодальные модели) к надписям Старшим, Младшим или Англосаксонским футарком. Малочисленные смежные работы относятся либо к древнетюркскому руническому письму, либо к традиции 3D-сканирования рунических камней.

1.1 Трансформерные архитектуры в распознавании рукописного текста

В период 2020–2022 гг. трансформерные архитектуры начали вытеснять традиционные конвейеры CNN + BiLSTM + CTC в задачах распознавания рукописного текста. Kang и др. [19] предложили одну из первых полностью трансформерных архитектур HTR, объединившую визуальный экстрактор ResNet-50 с мультиголовым самовниманием на визуальной и текстовой сторонах, и достигли на корпусе IAM CER около 4,67 % при обучении на синтетических строках. Diaz и др. [20] провели систематическое сравнение энкодер-декодерных пар и показали, что Transformer-энкодер в роли последовательностного экстрактора превосходит рекуррентные альтернативы, тогда как авторегрессивный Transformer-декодер не даёт прироста на коротких строковых задачах. Переход к страничному распознаванию совершила архитектура DAN (Document Attention Network) Coquenet и др. [21], объединившая FCN-энкодер с трансформерным декодером, генерирующим символы вместе с тегами логической структуры.

Также для развития исторического OCR важна архитектура HTR-VT [22] – чисто энкодерный ViT с CNN-эмбедингом, обучаемый без внешних данных: он достигает CER 4,7 % на IAM и 3,9 % на READ 2016. Авторы особенно отмечают важность абляции: удаление CNN-фронтенда поднимает CER на IAM с 3,3 % до 26,6 %, что опровергает представление о «чистом» трансформере как универсальном решении для распознавания письма и обосновывает гибридную CNN + Transformer-схему как методологическую норму. Однако ни одной публикации, применяющей ViT-семейство к руническим скриптам в полноценном HTR-режиме, обнаружить не удалось.

1.2 TrOCR и адаптация к историческим документам

Модель TrOCR [6] стала стандартом современных исследований распознавания исторического письма. Её архитектура объединяет энкодер типа ViT/BEiT/DeiT с декодером типа RoBERTa/MiniLM и обучается на двухступенчатом конвейере из сотен миллионов синтетических печатных и миллионов рукописных строк, достигая на IAM CER 2,89 % (вариант LARGE), 3,42 % (BASE) и 4,22 % (SMALL). Ценность TrOCR для эпиграфики определяется не столько абсолютными результатами, сколько возможностью дообучения относительно небольшим числом размеченных строк. Этот вопрос систематически изучен Ströbel и др. [23]: дообученный TrOCR-LARGE превосходит специализированную систему Transkribus HTR+ на исторических письмах XVI в. уже после пятнадцати эпох. Последующая работа [24] уточняет, что устойчивое превосходство над свёрточно-рекуррентными моделями демонстрирует только вариант LARGE.

Систематическое продолжение представлено у Parres и Paredes [25], где конфигурация Vision Encoder–Decoder даёт WER 6,9 % на ICFHR 2014 Bentham и 14,5 % на ICFHR 2016 Ratsprotokolle. Авторы показывают, что при кросс-языковой адаптации необходимо дообучать и декодер, а его замораживание ведёт к потере 3–5 п.п. CER. Декодер-only модель DTrOCR [26] доводит IAM до CER 2,38 %, формируя новый ориентир. Адаптация TrOCR к средневековым рукописям закреплена в проекте CATMuS Medieval [27]. Самообучаемое предобучение трансформерных распознавателей развивают работы Souibgui и др. [28], применившие masked-image-modelling с реконструкцией деградации, что особенно ценно для деградированных каменных носителей. Vogler и др. [29], показали, что тридцати размеченных строк достаточно для адаптации MAE-предобученного энкодера к новой рукописной традиции – это наиболее прямой методологический ориентир для рунической задачи. Применений TrOCR к руническим надписям нам не удалось обнаружить в рецензируемых индексируемых изданиях.

1.3 Мультимодальные модели в OCR исторических документов

Распространение визуально-языковых моделей в 2023–2025 гг. породило волну попыток оценить их пригодность для исторического OCR. Архитектурный ландшафт задают LLaVA [30], семейство Qwen-VL [31], InternVL [32], MiniCPM-V [33] и Florence-2 [34], чьи способность к OCR-with-region и открытая лицензия делают её привлекательным кандидатом для дообучения на эпиграфических корпусах; закрытые GPT-4V/4o и Gemini [35] остаются бенчмарками для zero/few-shot-экспериментов. Систематическая оценка OCR-способностей

этих моделей закреплена в OCRBench [36] и его расширении OCRBench v2 [37]: 36 из 38 оценённых моделей получили менее 50 из 100 баллов, причём систематические провалы приходятся на редкие скрипты, мелкие символы и нестандартную композицию – все три характеристики применимы к рунической эпиграфике.

Для древних языков ориентиром остаются работы группы DeepMind/Oxford: Pythia [1], Ithaca [2] и мультимодальная Aeneas [3], выполняющие реставрацию лакун, географическую атрибуцию и датировку греческих и латинских надписей. Cowen-Breen и др. [38] предлагают instruction-tuned causal LM, конкурирующий с Ithaca, что отражает миграцию методологии в сторону декодер-only моделей. Систематических оценок мультимодальных моделей на руническом материале не обнаружено.

1.4 Детекторы объектов для эпиграфики

В типичном эпиграфическом конвейере детекция строк или знаков предшествует распознаванию, поэтому ландшафт детекторов остаётся существенным. Семейство YOLO [39, 40] прошло путь от ранних версий без формальной публикации до архитектур с программируемым градиентом и NMS-free-обучением. При этом сравнительные оценки на нестандартных доменах показывают, что новизна версии не гарантирует превосходства на узких исторических данных. Специализированные текстовые детекторы CRAFT [41] и DBNet [42] остаются обязательным компонентом эпиграфических конвейеров, поскольку строки на каменных носителях искривлены и повернуты.

Особенно важна для рунических надписей ветвь ориентированных ограничивающих рамок (Oriented Bounding Box, OBB): рунические строки на стелах нередко идут под произвольными углами, по дугам или спиралям. Ключевые ориентиры – Oriented R-CNN [43] и ReDet [44], а также OBB-варианты детекторов YOLO. Обзор сегментации строк и детекции базовых линий в исторических документах [45] и работа YOLO-HTR [46], интегрирующая YOLO-детектор с Vertical Attention Network, систематизируют методическую базу. Прямых применений OBB-семейства к руническим надписям не опубликовано, что образует ещё одну отчётливую лакуну.

Тем не менее, специфика рунического материала вносит существенные коррективы в классическую каскадную схему компьютерного зрения. Полное отсутствие публично доступных размеченных корпусов с посимвольной или строчной локализацией, а также критически малый объем дошедших до нас физических артефактов делают обучение робастных OBB-детекторов «с нуля» практически нереализуемым на данном этапе. Более того, высокая

степень эрозии и фрагментарности носителей приводит к тому, что границы отдельных знаков или строк оказываются семантически размытыми даже для экспертов-рунологов. По этой причине в рамках данного исследования обосновывается отказ от традиционного двухэтапного конвейера «детекция → классификация» в пользу сквозного (end-to-end) распознавания целых текстовых полей методами мультимодальных трансформеров.

1.5 Рунические надписи: цифровая рунология и состояние корпуса

1.5.1 Корпуса и инфраструктура

Стержневым инфраструктурным проектом для германских рун является RuneS (*Runic Writing in the Germanic Languages*) [47] при Союзе академий наук Германии, охватывающий руническое письмо примерно AD 100–1500 и агрегирующий данные Кильского рунического проекта, датского регистра и Скандинавской руно-текстовой базы под открытыми лицензиями. RuneS, однако, ориентирован на хранение, систематизацию и типологическое описание рунических данных и не предназначен для разработки или оценки моделей машинного обучения. В доступной литературе не обнаружено нейросетевых исследований, непосредственно использующих инфраструктуру RuneS. Параллельная скандинавская инфраструктура опирается на Rundata / Samnordisk runtextdatabas [48]. Несмотря на статус стандартного транскрипционного корпуса, в рецензируемой литературе не выявлено ни одной работы, где Rundata использовалась бы как обучающий или валидационный материал для машинного обучения. Программа *Everlasting Runes* и обзорная статья Källström [49] о корпусных изданиях шведских рунических надписей также носят характер цифрового документирования без ML-методологии.

1.5.2 Традиция 3D-сканирования

Наиболее зрелым вычислительным направлением для германских рун является не глубокое обучение, а анализ структуры поверхности средствами 3D-лазерного сканирования. Наиболее цитируемая работа Imer, Kitzler Åhfeldt и Zedig [50] показывает, что 3D-сканирование в сочетании с РСА позволяет идентифицировать работы мастеров и связать камни Йеллинга с конкретным резчиком. Указанные ограничения подхода – малый размер выборки, субъективность интерпретации и шум, обусловленный выветриванием памятников, — существенно ограничивают применимость описанных методов и указывают на перспективность использования нейросетевых подходов метрического обучения. Группа открыла 3D-датасеты, на которые легли в основу их исследования, однако предложенные наработки не применимы в

контексте данной задачи.

1.5.3 Состояние цифровой рунологии и единичные нейросетевые работы

Анализ работ последних опубликованных томов журнала *Futhark* (2020–2024) ясно показывает: ни одна статья не применяет машинное обучение или компьютерное зрение к руническим надписям, что может говорить о малом освещении использования методов ML для «рунических» скандинавских алфавитов. Реальный объём нейросетевых публикаций по «руническим» скриптам сосредоточен в области древнетюркской руники, названной «рунической» в силу визуального сходства с германскими футарками, но лингвистически восходящей к арамейскому письму. Эти работы остаются ближайшими методологическими ориентирами. Mukashev и Tukeyev [14] описывают нейросетевой конвейер распознавания орхонских рун, хотя полное описание архитектуры и метрик найти не удалось в открытом доступе. Taheri и др. [15] обучают компактную CNN на 38 классах древнетюркских символов и сообщают точность 96,3 %, признавая ограничения – крохотный исходный датасет и потерю деталей штриха. Методологически полной является работа Derin и Uçar [13], где Vision Transformer обучается на полностью синтетических данных, полученных через параметрическую рандомизацию и физически-основанный рендеринг в Blender, и применяется в zero-shot-режиме к фотографиям камня Кюль-Тегина с высокой точностью. Этот результат – наиболее прямой ориентир для настоящей работы: он демонстрирует, что синтетический рендеринг каменной поверхности с параметризованной деформацией графом способен заменить размеченный корпус, что прямо отвечает на главное ограничение рунической задачи.

1.6 Методологические аналогии из смежных малоресурсных доменов

Вследствие ограниченности корпуса работ по автоматической обработке рунических надписей методологические ориентиры целесообразно искать в смежных малоресурсных предметных областях, характеризующихся сходными ограничениями данных и задачами распознавания. Наиболее проработанный пример – клинопись. Dencker и др. [51] вводят слабосупервизорное итеративное обучение детектора знаков на основе выравнивания латинских транслитераций с изображениями, получая 8109 размеченных знаков 186 классов без дорогой плотной разметки. Эта идея напрямую переносима на рунический материал, где транслитерации Rundata могут выступить тем же выравнивающим сигналом. Гейдельбергская группа [52] развивает 3D-подход, приводящий задачу к квазидвумерной форме через анализ кривизны поверхности.

Отдельную методическую линию образует синтетическая генерация изображений, центральная для малоресурсной задачи. Базовые диффузионные модели [53] и условный контроль через ControlNet [54] обеспечивают управляемый синтез даже при ограниченных обучающих данных. Линия GAN-синтеза рукописного письма представлена ScrabbleGAN [55]. Также, для условий малой выборки релевантны канонические методы few-shot- и self-supervised-обучения.

1.7 Идентифицированные лакуны и позиционирование работы

Проведённый обзор позволяет зафиксировать ряд лакун, образующих обоснование настоящей работы. Во-первых, отсутствует нейросетевая модель распознавания, обученная или адаптированная под Старший, Младший или Англосаксонский футарк, тогда как смежные традиции – клинописная, оракульностная, греко-латинская, египтологическая, майяская – уже располагают собственными ML-направлениями. Во-вторых, существующие скандинавские 3D-корпуса анализируются исключительно классической многомерной статистикой. В-третьих, автоматическая сегментация рунических знаков на фотографиях не реализована: ни детекторы YOLO/DETR, ни OBB-семейство к корпусу германских рунических камней в опубликованной форме не применялись. В-четвёртых, синтетическая генерация рунических изображений с физически-основанным рендерингом и моделированием выветривания не разработана, хотя прямые шаблоны для близких доменов уже существуют. Наконец, систематические оценки мультимодальных моделей на руническом материале отсутствуют.

Таким образом, современная литература по распознаванию исторических эпиграфических надписей вышла на технологический уровень, существенно превышающий уровень любых опубликованных работ по руническому материалу. Настоящая работа позиционируется как систематический перенос методологии из перечисленных смежных областей на корпус скандинавских рунических надписей, опирающийся на инфраструктуру RuneS и Rundata и на методы синтетической генерации.

2 Лингвистические и материальные основания задачи

2.1 Рунические письменные системы: графемный инвентарь и история

В отличие от типичной задачи OCR, где разнообразие исходных алфавитов покрывается единой моделью на уровне Unicode-кодов, рунический материал распадается на три исторически различные системы – Elder Futhark, Younger Futhark и Anglo-Saxon Futhorc,

каждая со своим графемным инвентарём, своим соотношением знака и фонемы и своим репертуаром носителей. Эти различия прямо переводятся в инженерные параметры задачи: размер пространства классов, степень омонимии знака, ожидаемый уровень доменного сдвига между сегментами выборки и допустимую структуру целевой метрики. Поэтому каждое свойство системы соотносится ниже с конкретной трудностью, которую она создаёт для классификатора графем и последующего лингвистического слоя.

2.1.1 Старший футарк

Старший футарк (Elder Futhark) – древнейшая засвидетельствованная германская рунописная система, фиксируемая на территории от южной Скандинавии до Карпатского бассейна приблизительно со II по VIII в. н. э., с пиком документации между серединой III и серединой VII в. [56, 57, 58]. Канонический инвентарь состоит из двадцати четырёх знаков, организованных в три группы по восемь рун (*ættir*); порядок групп и последовательность знаков сохраняются во всех известных полных рядах, начиная с надписи на камне из Килвера (Готланд, около 400 г. н. э.), где система впервые засвидетельствована в каноническом порядке *f u þ a r k g w | h n i j ð p z s | t b e m l ŋ d o* [59, 60].

Лингвистическим основанием системы считается принцип «один знак – одна фонема»: набор графем приблизительно соответствует фонемному инвентарю прагерманского и раннеобщескандинавского [60, 56]. Однако, этот принцип может и нарушаться. Графема *ð* не имеет устойчивого фонетического значения и в разных интерпретациях возводится к долгому переднему гласному либо к специфическому рефлексу прагерманского, что отражает реальную неопределённость прочтения [59, 58]. Систематически фиксируются связанные руны (*bind-runes*) и зеркальные начертания, обусловленные эстетикой носителя и техническими ограничениями резца [56]. Тем не менее степень омонимии графем здесь относительно низка, и в нормативной транслитерации большинство знаков отображается на единственную фонему.

Корпус Старшего футарка географически и материально разнороден, что определяет визуальную гетерогенность доступной выборки: помимо камня из Килвера, опорными памятниками являются железные наконечники копий из Эвре-Стабу и находки из болота Иллеруп-Одаль, а существенный сегмент образуют золотые брактеаты V–VI вв. [56, 57]. Таким образом, система документирована на камне, железе, драгоценных металлах, кости и органике в той мере, в которой сохранились источники [56, 58].

Для распознавания отсюда следует двойственный вывод. Относительная фонематическая прозрачность делает классификацию графемы внутри этой системы концептуально

более чистой, чем в Младшем футарке: верно опознанный знак в большинстве случаев соответствует единственной фонеме, и ошибки CER близки к ошибкам на фонемном уровне. Однако материальная и хронологическая разнородность корпуса формирует значительный внутрисистемный доменный сдвиг: модель, обученная преимущественно на камне, не переносится на металлические подложки без доменной адаптации. Малочисленность сохранившихся надписей превращает Старший футарк в типичный малоресурсный сегмент, где обучение без few-shot learning и синтетической аугментации невозможно.

2.1.2 Младший футарк

Переход к Младшему футарку (Younger Futhark), завершившийся к концу VIII в. [61, 62], образует одну из наиболее обсуждаемых проблем рунологии и узловой пункт для постановки задачи фонемного распознавания. Проблема заключается в парадоксе редукции: число графем сокращается с двадцати четырёх до шестнадцати, тогда как фонологическая система древнескандинавского языка в тот же период усложняется (формируются новые гласные качества как результат i- и u-перегласовки, развиваются длительностные противопоставления, дифференцируются носовые) [61, 58]. Шульте описывает это движение как «невидимую руку перемен», где функциональная редукция инвентаря сопровождается, а не компенсируется, ростом фонологической сложности [61].

Механизм адаптации состоит в нейтрализующем слиянии противопоставлений на письме при сохранении их в речи. Противопоставления звонкости и глухости в смычных рядах /p/--/b/, /t/--/d/, /k/--/g/ исчезают с графемного уровня: одна руна обслуживает обе фонемы. Графема *kaup* функционирует как письменное выражение по меньшей мере трёх единиц – /k/, /g/ и носового /ŋ/ перед велярным смычным, а *týr* передаёт и /t/, и /d/ [57, 58, 63]. Знак и фонема находятся в отношении «один-ко-многим», и разрешение неоднозначности возможно лишь на уровне лексического и контекстного знания.

Отсюда следствие для метрик качества. Если классификатор правильно распознал визуальный знак *kaup*, метрика CER на уровне графем фиксирует успех, однако при выходе на фонологическую транскрипцию та же графема может соответствовать /k/, /g/ или /ŋ/, и фонемная ошибка возникнет независимо от качества визуальной классификации. Таким образом, графемный CER в Младшем футарке систематически не эквивалентен фонемному.

Внутренняя организация Младшего футарка неоднородна: уже в IX в. выделяются три региональные ветви. Длинноветвистые (long-branch, датские) руны представлены полными вертикалями и развитыми наклонными ветвями, коротковетвистые (short-twig,

шведско-норвежские) редуцируют ветви до коротких штрихов, а хэльсингские (staveless) руны удаляют у ряда знаков основной ствол [58, 63, 57]. С точки зрения компьютерного зрения три ветви образуют три различных пространства аллографов одного фонемного инвентаря, что значимо для построения system-aware заголовка классификатора. Количественная плотность корпуса значительно превосходит плотность Старшего футарка: число рунических камней с надписями Младшего футарка в одной только Швеции оценивается приблизительно в 1700–2500 объектов. Это означает, что в Rundata Младший футарк доминирует и формирует значительный class imbalance относительно остального материала. Наиболее протяжённой надписью является камень из Рёка (около 800 г. н. э.), включающий, по разным подсчётам, более семисот рун и одновременно использующий short-twig руны, отдельные знаки Старшего футарка и шифровальные системы [58].

2.1.3 Англосаксонский футорк

Англосаксонский футорк (Anglo-Saxon Futhorc) развивается на острове и на фризской периферии в противоположном направлении: вместо редукции инвентарь расширяется под действием фонологических сдвигов древнеанглийского. Стандартный ряд включает двадцать восемь знаков; рукописные ряды (Cotton Domitian A.IX и др.) фиксируют расширение до тридцати трёх рун [64, 65, 66]. Позднейший пласт (*þ, calc, gar, stan*), документированный почти исключительно в рукописях, Пейдж характеризует частично как «псевдо-руны», изобретённые для соответствия латинскому алфавиту [64, 65]. Для классификатора это означает, что пространство классов не фиксировано априорно и зависит от состава обучающей выборки: модель, обученная только на каменной эпиграфике, может не встретить *þ*.

2.1.4 Следствия для архитектурных решений

Сопоставление трёх систем даёт четыре вывода для проектирования модели. Во-первых, размер классификационного пространства варьируется от шестнадцати классов до приблизительно тридцати трёх при крайне неравномерном распределении примеров, что требует взвешенной функции потерь либо стратифицированной выборки. Во-вторых, омонимия в Младшем футарке создаёт неустранимую неопределённость ground truth на уровне фонологической транскрипции, и оценка модели может учитывать это через отдельные метрики CER (графемный) и PER (фонемный). В-третьих, поскольку правила соответствия графемы и фонемы зависят от системы, классификатор должен быть условен по идентификатору системы – требуется system-aware classifier head, переключаемый априорным предсказанием

системы.

Таблица 2.1 систематизирует ключевые параметры трёх систем в форме, пригодной для прямого соотнесения с инженерными решениями.

Таблица 2.1: Сравнительная характеристика рунических письменных систем

Параметр	Elder Futhark	Younger Futhark	Anglo-Saxon Futhorc
Период	ок. 150–700 н. э.	ок. 800–1100 н. э.	ок. 650–1100 н. э.
Кол-во знаков	24	16	28 (станд.) – 33 (расш.)
Знаков на фоне-му (макс.)	1 (с редкими ис-кл.)	до 3 (<i>kaun</i> = /k/, /g/, /ŋ/)	1–2 (палатализация /k/, /g/)
Носители	камень, металл, кость, дерево (фрагм.)	камень, металл, кость, дерево	камень, кость, металл, пергамен (<i>runica manuscripta</i>)
Лигатуры	регулярно	реже, засвидетельствованы	регулярно, особенно в рукописях
Следствие для CV/OCR	малый корпус, высокий доменный сдвиг по материалам	class imbalance в Rundata, графемно-фонемный разрыв	максимальный медиальный сдвиг (камень ↔ пергамен)

2.2 Физическая деградация носителей как задача компьютерного зрения

Переход от лингвистического описания к материальному воплощению вводит второе принципиальное отличие рунической задачи от стандартного OCR. В документном OCR физическая деградация (пятна, разводы чернил, искажения сканирования) представляет собой технический шум, аддитивный по отношению к чистому сигналу и в значительной степени удалимый классическими методами. В эпиграфическом домене химические и биологические процессы изменяют именно те признаки – локальный контраст, текстурный градиент, цветовую вариативность, – на которых классические алгоритмы основывают извлечение сигнала. Деградация рунического носителя является, таким образом, не аддитивным, а структурным шумом, визуально неотличимым от сигнала средствами классического компьютерного зрения. Это и обосновывает отказ от Otsu, Sauvola и Canny как основных (а не вспомогательных) методов извлечения знака и переход к нейросетевому подходу. Объёмные методы документации (3D-сканирование, RTI) в работе не используются и упоминаются лишь как смежное направление.

2.2.1 Типология носителей и механизмы деградации

Камень составляет численно доминирующую категорию корпуса и наиболее уязвим для долгосрочных погодных и физико-химических воздействий. На большинстве снимков видны результаты воздействия лишайников и мхов на поверхность: под их воздействием разрушаются исходные текстуры, что приводит к размытию границ рун. Параллельно идёт колонизация мхами, усиливающими разрушение в циклах замерзания–оттаивания.

Деградация металлических носителей происходит по-разному: в зонах антропогенного реза коррозия развивается иначе, чем на нетронутой поверхности, благодаря этому есть возможность отделить намеренный рез от случайного повреждения носителя.

Кость и рог, представленные мелкими артефактами, подвержены дегидратации и денатурации коллагена. Продольное растрескивание создаёт паттерн линейных разрывов, визуально близкий к резу и образующий ещё один источник ложноположительных детекций. Дерево как носитель в европейском климате почти полностью утрачено. Деревянный сегмент географически локализован и обладает специфическим визуальным режимом, не моделируемым аугментациями каменного материала.

2.2.2 Спектральная неоднозначность

Механизмы деградации сходятся в одной проблеме компьютерного зрения: антропогенный рез и естественное повреждение на двумерной фотографии обладают почти идентичными характеристиками локального цвета, контраста и градиента яркости. В пространстве низкоуровневых дескрипторов класс «руническая линия» неотделим от класса «естественная неоднородность поверхности».

Условия съёмки влияют на эту неотделимость сильнее, чем выбор алгоритма обработки. Боковое касательное освещение подчёркивает рельеф и делает рез различимым, но одновременно усиливает все естественные неровности [67, 68]. Диффузное освещение нивелирует рельеф и удаляет тени, улучшая цветовую однородность, но лишая изображение информации о глубине реза. Различные сочетания угла и спектра подсветки дают радикально несхожие изображения одной надписи, и эта чувствительность образует ещё один источник доменного сдвига, действующий на уровне процедуры съёмки.

2.3 Инфраструктура цифровых рунических корпусов

2.3.1 Samnordisk runtextdatabas (Rundata)

База Samnordisk runtextdatabas (далее – Rundata), известная также как Scandinavian Runic-text Database (SRD), является стандартным транскрипционным корпусом скандинавских рунических надписей. Проект возник в Уппсальском университете на рубеже 1980–1990-х годов: первая версия собрана в 1987 г. на основе локальной базы шведских надписей, а финансирование для расширения до общенордического охвата получено в 1992 г. [69]. Корпус последовательно эволюционировал (Rundata 1.0, 2001; 2.5, 2007; 3.0, 2008; 3.1, январь 2018), и с декабря 2020 г. основная пользовательская поддержка перенесена на веб-платформу Runor под управлением Шведского управления по охране культурного наследия (Riksantikvarieämbetet).

Ограничение Rundata для задач компьютерного зрения состоит в том, что подавляющее большинство записей содержит только текстовую информацию – транслитерацию, нормализацию, перевод, библиографические ссылки и другую метаинформацию – и не имеет привязанных машиночитаемых изображений. Изображения отдельных надписей частично доступны через интерфейс Runor, где Riksantikvarieämbetet интегрирует фотодокументацию из собственных и партнёрских архивов [70], однако ни покрытие, ни разрешение, ни условия съёмки этих изображений не унифицированы, и формальной связки «текстовая запись ↔ массив изображений с фиксированными метаданными» в базе не предусмотрено. Это означает, что прямое использование Rundata как обучающего датасета CV-модели невозможно: база предоставляет богатую целевую разметку (ground truth по транслитерации, нормализации и атрибуции), но без предварительной и основательной ручной обработки данные не применимы. Этим же ограничением объясняется, почему в рецензируемой литературе не выявлено ни одной ML-публикации, использующей Rundata как тренировочный материал, несмотря на то что сообщество явно признает такую возможность как нерешённую инфраструктурную задачу [71, 5].

2.3.2 Альтернативные базы и корпусные ресурсы

Вторую цифровую инфраструктуру предоставляет проект RuneS («Runic Writing in the Germanic Languages») Союза академий наук Германии (Akademie der Wissenschaften zu Göttingen) действующий с 2010 г. и охватывающий руническое письмо примерно со 100 по 1500 г. н. э. [72, 47]. В отличие от Rundata, фокусированной на скандинавском ареале, RuneS систематически включает южногерманский корпус, англо-фризский футорк и руническую рукописную традицию. База содержит отдельный модуль аллографов и графотипических

вариантов с описанием формы знака на уровне отдельных штрихов, чего в Rundata нет. Технически RuneS реализован как веб-интерфейс с возможностью браузерного поиска. Лицензионный режим напрямую допускает использование данных в обучении ML-моделей при атрибуции и сохранении лицензии [47]. При этом RuneS, как и Rundata, не предоставляет в открытом доступе унифицированных изображений, пригодных для обучения CV-моделей.

Nationalmuseet Danmark поддерживает базу Danske Runeindskrifter (свыше 900 датских надписей с фотодокументацией) [73]; Kulturhistorisk museum в Осло поддерживает Runic Archives (свыше 1600 норвежских надписей) [74]; The British Museum предоставляет открытый коллекционный API с фотографиями отдельных англосаксонских артефактов; Europeana функционирует как наднациональный агрегатор кросс-институционального поиска [75]. Качество и формат изображений в этих репозиториях различны: разрешение варьирует от низкокачественных архивных сканов начала 2000-х до современных профессиональных фотографий; условия освещения не унифицированы, а оптимальная для эпиграфики raking light-съёмка применяется крайне редко.

2.3.3 Архитектурные ограничения для машинного обучения

Перечисленные ресурсы создают для машинного обучения четыре связанных ограничения.

Первое – разрыв между разметкой и сигналом, описанный выше: целевая транслитерация существует в Rundata и RuneS, но входные изображения приходится извлекать и предобрабатывать отдельно.

Второе – неравномерность распределения по системам и периодам. Распределение записей радикально несбалансировано: на Младший футарк приходится подавляющее большинство записей, Старший футарк представлен примерно на порядок меньшим числом надписей; Англосаксонский футарк представлен менее чем двумястами надписями [64, 70]. Это распределение отражает археологические факторы сохранности, и его нельзя выровнять добавлением новых записей, только посредством обогащения выборки синтетическими данными. Class imbalance имеет двухуровневую структуру – на уровне систем и на уровне отдельных графем внутри системы – и, как показано в типологии доменного сдвига, напрямую транслируется в диахронический сдвиг между сегментами выборки. Обучение на полной выборке без коррекции сводит baseline-предсказание к мажоритарному классу Младшего футарка, что требует взвешенной функции потерь, стратифицированной выборки либо отдельных моделей с system-aware classifier head.

Третье – несовместимость нотаций между базами. Одна и та же надпись в Rundata, RuneS и национальных каталожных изданиях может иметь различную транслитерацию – не из-за ошибок, а из-за различий редакционных конвенций. Williams, Bianchi и Zimmermann [71] документируют расхождения и показывают, что для отдельных надписей четыре основных источника могут давать четыре несовпадающие транслитерации, отличающиеся не только в спорных позициях, но и в общем числе графем. Отсюда требование явного выбора единого референсного стандарта и ведения «лога расхождений» – сохранения альтернативных транслитераций как дополнительных полей.

Четвёртое – ограничения Unicode. Блок Runic (U+16A0–U+16FF), введённый Unicode 3.0 (1999) и расширенный восемью знаками в Unicode 7.0 (2014), содержит 89 кодпунктов, унифицирующих графемы трёх рунических систем, средневековые скандинавские руны и символы рунических календарей [76]. Принципиальное ограничение, разбираемое у Magin и Smith [5], в том, что кодпункт-уровень не различает аллографы: один кодпункт покрывает все графические варианты знака – закруглённые, угловатые, зеркальные, с разной длиной плеч. Текущая реализация блока несовместима ни с задачей структурированного поиска по аллографам, ни с задачей классификации, различающей аллографы как отдельные классы. Авторы констатируют, что спустя почти 25 лет после введения блока рунологии в массе своей им не пользуются [5]. Для машинного обучения это означает, что Unicode-кодпункт не может служить меткой классификатора аллографов. В экспериментальной части исследования была предпринята попытка дообучить OCR на транслитерированной версии текста, то есть без использования рун из блока Runic.

2.3.4 Стратегия интеграции в ML-конвейер

Из перечисленных ограничений вытекает практическая стратегия использования ресурсов в настоящей работе. Полноценная сборка реального изобразительно-текстового корпуса обучающего объёма потребовала бы автоматизированного связывания текстовых записей с изображениями с ручной валидацией каждой пары – задача, несоразмерная рамкам настоящей работы и выносимая в перспективы как самостоятельная инфраструктурная проблема. Поэтому Rundata используется здесь как источник транслитерационной лексики для синтеза.

Таблица 2.2 систематизирует характеристики основных ресурсов.

Таблица 2.2: Сравнительная характеристика рунических цифровых ресурсов

База	Институция	Объём изображе- ния	/ Лицензия	Применимость для ML
Rundata (SRD)	Uppsala Univ.	~7000 записей; изображений в базе нет	ODbL + DbCL	целевая разметка без входного сигнала; нужно связывание
RuneS	Göttingen, Kiel, Eichstätt	Старший, англо-фризский, Младший футарк; ~7000 записей	CC-BY-SA 4.0	детальная палеографическая и аллографическая разметка
Söktjänsten Runor	Riksantikvarie- ämbetet	~7000 агрегир.; изображения фрагментарны	CC0 (метаданные); CC-BY (изобр.)	основной доступный источник изображений
RUNOR	open-source	~1500 записей, Старший, Младший футарк;	MIT License	требуется ручная разметка

2.4 Конвенции транслитерации и формализация эпиграфической неопределённости

Прежде чем обучать модель на рунических данных, необходимо решить вопрос, который не возникает в стандартных OCR-задачах: что именно считать правильным ответом. В рунологии необходимо рассматривать его сразу на двух уровнях. На первом – выбор транслитерационного стандарта: параллельно существует несколько конкурирующих конвенций, каждая из которых по-своему кодирует знаки Младшего футарка и систему обозначений неуверенного прочтения. На втором – сама надпись: даже зафиксировав единый стандарт, мы сталкиваемся с тем, что значительная доля надписей допускает несколько равноправных прочтений, между которыми консенсус рунологов не достигнут.

Для машинного обучения оба фактора имеют прямые методологические последствия. Если целевая метка y , относительно которой измеряется отклонение предсказания, оказывается недоопределённой, то интерпретируемость стандартных метрик – CER, sequence accuracy, F1 по графемам – теряется: численное значение ошибки зависит от того, какое именно из допустимых прочтений выбрано в качестве эталона. В разделе формализуются оба источника неопределённости и описываются конвенции, принимаемые в настоящей работе.

2.4.1 Множественность стандартов транслитерации

Транслитерация (конверсия «руна → латинская буква или диграф») принципиально отличается от транскрипции, то есть нормализации к стандартному древнескандинавскому или

древнеанглийскому [63, 58]. Она формально однозначна по построению: каждой графеме приписывается каноническое латинское соответствие безотносительно реально передававшегося звука. Однако, в рунологии устоялась не одна традиция транслитерации.

Конвенция Rundata опирается на принципы, восходящие к работам Лены Петерсон [77]. Для Младшего футарка она принимает «уплощённую» нотацию: *kaun* систематически транслитерируется как **k**, хотя передаёт /k/, /g/ и /ŋ/; *týr* – как **t**, передавая /t/ и /d/; *ár* – как **a**, передавая /a/, /æ/, /e/ и назализованный /ã/ [63, 57]. Нотация повреждённых прочтений кодифицирована так: квадратные скобки – восстановленная часть; курсив или подчёркивание – неуверенные знаки; знак вопроса – альтернативное прочтение; многоточие – лакуна; круглые скобки – редакторские дополнения [77]. Эта система, удобная для филологического чтения, при буквальном переносе в обучающую разметку создаёт сложности: специальные символы интерпретируются токенайзером как обычные графемы и портят словарь меток.

Классическая система Краузе–Янкуна (KJ), опубликованная в *Die Runeninschriften im älteren Futhark* [59], остаётся стандартом транслитерации Старшего футарка и отличается от Rundata большей детализацией: последовательнее разделяет аллографы, использует диакритические знаки для особых рун и систематически применяет звёздочку для реконструированных форм [59, 60]. Поскольку для записей Старшего футарка Rundata в значительной мере воспроизводит KJ-конвенции, а собственная конвенция Rundata оптимизирована под Младший футарк, корпус демонстрирует внутреннюю стилистическую неоднородность транслитераций между сегментами.

Принципы RuneS опубликованы как часть документации базы [47]. Они агрегируют разные источники с сохранением происхождения: транслитерации Старшего футарка заимствуются из Runenprojekt Kiel, датские надписи Младшего футарка – из Danske Runeindskrifter, прочие скандинавские – из Rundata 2.5, англо-фризские – собственные принципы RuneS. RuneS не унифицирует эти конвенции в единый стандарт, что для машинного обучения означает дополнительный источник неоднородности целевых меток. Национальные печатные стандарты служили референсами для Rundata, но каждый использует собственные конвенции передачи специальных знаков и обозначения лакун [71].

2.4.2 Эпиграфическая неопределённость как проблема ground truth

Даже после фиксации единого стандарта значительная доля надписей сохраняет неустранимую неопределённость прочтения, имеющую несколько источников. Во-первых, физическая повреждённость: эрозия, сколы и трещины приводят к тому, что отдельные графемы

видны лишь частично, и полная и однозначная трактовка знака невозможна. Во-вторых, графематическая полифония Младшего футарка, где одна графема соответствует нескольким фонемам и выбор возможен лишь на уровне контекстной интерпретации. В-третьих, аллографическая интерпретация: на пограничных случаях длинноветвистая и коротковетвистая формы допускают двойное отнесение, и разные рунологи классифицируют один физический рез как реализацию разных графем. В-четвёртых, чтение направления и порядка: в спирально или дуговидно расположенных надписях направление устанавливается лишь с привлечением иконографического и формульного анализа [78, 79].

Эпиграфическая неопределённость не может быть устранена ни более качественным изображением, ни лучшей моделью – она встроена в природу источника. Это означает, что классическое понятие *ground truth*, являющееся базовым для машинного обучения, применительно к рунической OCR оказывается недоопределённым.

2.4.3 Формализация неопределённости для машинного обучения

Первый возможный подход – жёсткая фильтрация: из обучающей выборки исключаются все надписи с маркерами неуверенного прочтения. Подход прост и даёт корректно интерпретируемый CER на оставшейся выборке, но сильно сокращает объём данных и систематически смещает распределение в сторону лучше сохранившихся камней. Обученная на этом подмножестве модель может показывать заниженный CER на *in-distribution*-тесте и резко более высокий – на повреждённых надписях, к работе с которыми и стремится практика.

Второй подход – мягкая разметка (*soft labeling*): метка превращается из единственной строки в распределение вероятностей по альтернативным прочтениям. На уровне отдельного знака мягкая метка задаётся как распределение $p_i(c)$ по множеству допустимых графем:

$$p_i(c) = \begin{cases} 1, & c = c_i^* - \text{уверенное прочтение} \\ \frac{1}{|\mathcal{A}_i|}, & c \in \mathcal{A}_i - \text{множество альтернатив} \\ 0, & \text{иначе} \end{cases} \quad (1)$$

где $\mathcal{A}_i$ – экспертно-определённое множество альтернативных графем в позиции i для неуверенно прочитываемого знака. Кросс-энтропийная функция потерь обобщается на *soft labels*:

$$\mathcal{L}_{\text{soft}}(\hat{p}, p) = - \sum_{i=1}^T \sum_{c \in \mathcal{C}} p_i(c) \log \hat{p}_i(c), \quad (2)$$

где $\hat{p}_i(c)$ – предсказанная вероятность графемы c в позиции i , $\mathcal{C}$ – полный графемный инвентарь, T – длина последовательности. Такая функция потерь не штрафует модель за предсказание любого из допустимых альтернативных прочтений, что соответствует признанию обоих вариантов экспертом.

Соответственно переопределяется и метрика. Стандартный CER рассчитывается как

$$\text{CER} = \frac{S + D + I}{N}, \quad (3)$$

где S , D , I – числа замен, удалений и вставок в редакционном расстоянии между предсказанной и эталонной строками, N – длина эталона. В случае мягкой разметки CER заменяется на ambiguity-aware CER (A-CER), в котором подстановка между двумя графемами, признанными альтернативами в данной позиции, считается не ошибкой, а корректным предсказанием:

$$\text{A-CER} = \frac{S^* + D + I}{N}, \quad S^* = \sum_i \mathbb{I}[\hat{c}_i \notin \mathcal{A}_i], \quad (4)$$

где $\hat{c}_i$ – предсказание модели в позиции i , а индикатор $\mathbb{I}[\cdot]$ возвращает единицу только тогда, когда предсказанная графема не входит в множество допустимых альтернатив. Эта метрика, идейно восходящая к обобщениям CER в литературе по NTR исторических документов, применительно к рунической эпиграфике формализуется здесь явно и используется параллельно со стандартным CER для разделения двух типов ошибок: подлинных ошибок распознавания и допустимых альтернатив.

Изложенный аппарат (1)–(2),(4) представляет формализацию, которую работа вносит как методологический задел. В текущей базовой постановке сознательно принята жёсткая разметка и стандартный CER (4), поскольку цель – установить воспроизводимый baseline на однозначных прочтениях, тогда как A-CER требует экспертно-размеченного множества альтернатив, формирование которого вынесено в перспективы.

2.4.4 Принятые в работе соглашения

Основным стандартом транслитерации выбрана конвенция Rundata. Важно, что транслитерация в этой конвенции выступает в работе не вспомогательным представлением, а целевым выходом системы распознавания: модель предсказывает латинскую строку Rundata (например, `fupark`), а не последовательность рунических кодовых позиций Unicode. Такой выбор устраняет необходимость расширения словаря токенизатора рунами блока U+16A0–U+16FF и позволяет переиспользовать предобученные субсловные словари без модификации,

что критично в условиях малого объёма данных.

Предобработка исходных транслитераций в обучающий корпус строится как нормализация к чистому графемно-транслитерационному ядру конвенции Rundata. Вся эпиграфическая разметка – разделители слов, скобочные обозначения лакун и неуверенных прочтений, маркеры лигатур (=) и альтернативных чтений (/), пометы строк и секций – трактуется как граница токена. Сохраняются лишь токены, целиком состоящие из символов допустимого транслитерационного алфавита (33 знака, включая þ, ð, æ, ø, ǣ, носовая R), при этом заглавная A приводится к строчной, а R и r сохраняются как различные графемы. Для генерации синтетических изображений очищенная транслитерация детерминированно отображается обратно в руны полной обратимой таблицей соответствий, целевой инвентарь которой составляют младшие руны long-branch как ядро, пунктированные руны для дополнительных фонем (e, g, d, p, y, o, c, z, v) и отдельные старшие/англосаксонские графемы для символов без младшефутаркового эквивалента (w, j, ð, i, η, æ, ø). Обратимость отображения обеспечивает строгое соответствие между изображением и меткой по построению, что исключает рассогласование разметки как источник шума в синтетических данных.

Из принятой процедуры следует явное разделение режимов учёта эпиграфической неопределённости. Синтетический корпус формируется из уверенных чистых прочтений, неопределённость и лакуны в него намеренно не вносятся, а его метки точны, что позволяет оценивать распознавание на нём стандартной метрикой.

Принятая совокупность соглашений – конвенция Rundata как стандарт транслитерации и одновременно цель распознавания, нормализация реальных транслитераций к чистому алфавиту, детерминированное обратимое отображение для синтеза и разделение режимов неопределённости между синтетическими и реальными данными – образует формальный аппарат, относительно которого далее описываются схема разметки корпуса, процедура его сборки и протокол оценки.

3 Эмпирическая база и формирование корпуса

Целевая разметка скандинавских надписей существует, однако привязанных к ней унифицированных машиночитаемых изображений нет, а связывание текстовых записей с фотографиями требует ручной валидации каждой пары. Из этого ограничения следует, что собрать реальный изобразительно-текстовый корпус объёмом, достаточным для обучения нейросетевого распознавателя «с нуля», что в рамках классического OCR требует десятки, а иногда и сотни тысяч верифицированных пар, в рамках настоящей работы невозможно.

3.1 Стратегия формирования данных: обучение на синтетике, оценка на реальном золотом стандарте

Эмпирическая база работы строится на принципиальном разделении источника обучающего сигнала и источника оценочного сигнала. Обучающая выборка формируется полностью синтетически: изображения рунических надписей генерируются управляемым конвейером, а их транслитерационные метки точны по построению благодаря обратимому отображению. Оценочная выборка, напротив, состоит исключительно из реальных фотографий надписей с выверенной транслитерацией и используется только для валидации и тестирования, но не для обучения.

Наиболее близкая по постановке работа Derin и Uçar [13] обучает Vision Transformer на полностью синтетическом корпусе древнетюркских руноподобных знаков, полученном параметрической рандомизацией и физически-основанным рендерингом, и применяет его в zero-shot-режиме к реальным фотографиям камня Кюль-Тегина с высокой точностью без единого реального обучающего примера. Тем самым связка «обучение на синтетике – оценка на реальных данных» для руноподобной эпиграфики является не обходным приёмом, а воспроизведением подтверждённой исследовательской парадигмы. Её дополняют два смежных результата: Vogler и др. [29] демонстрируют, что для адаптации предобученного энкодера к новой письменной традиции достаточно нескольких десятков размеченных строк, что оправдывает минимизацию объёма реальных данных; Dencker и др. [51] используют латинские транслитерации как выравнивающий сигнал для разметки знаков, что обосновывает выбор реальных транслитераций Rundata в качестве лексической основы синтеза.

В условиях, когда число доступных верифицированных реальных пар измеряется десятками, каждая такая пара обладает наибольшей ценностью именно как несмещённая точка оценки обобщающей способности, а не как один из многих обучающих примеров. Включение реальных данных в обучение одновременно загрязнило бы тестовую оценку утечкой распределения и одновременно сократило бы и без того малую тестовую выборку. Удержание всего реального множества вне обучения позволяет измерить величину, составляющую центральный эмпирический вопрос работы, – разрыв между синтетическим и реальным доменами (domain shift) для рунического письма.

Помимо этого, синтетический корпус формируется из уверенных чистых прочтений с точными метками, и качество на нём измеряется стандартным CER. Поскольку реальный верифицированный набор данных в рамках принятой методологии также приводится к однозначной строковой репрезентации, его валидация осуществляется по аналогичной схеме с

использованием классического посимвольного расстояния редактирования. Это обеспечивает полную метрическую унификацию между синтетическим и реальным доменами, позволяя напрямую оценивать величину падения точности при переносе модели.

Такой подход позволяет корректно интерпретировать целевой порог CER. Порог в 20 % понимается не как безусловный результат, а как априорно фиксируемая граница практической применимости: распознавание с долей посимвольных ошибок ниже этого уровня сохраняет полезность для индексирования, поиска по корпусу и последующей экспертной корректуры, тогда как обучение модели исключительно на синтетических данных оставляет открытым эмпирический вопрос о том, насколько близко к этой границе удаётся подойти при переносе на реальные носители. Порог 20 % принимается как рабочая инженерная граница, ниже которой выход пригоден для индексации и экспертной пост-корректуры. Он не претендует на универсальность и служит единой точкой отсчёта для интерпретации результатов. Соответственно, вклад экспериментальной части состоит не в гарантированном достижении порога, а в установлении первой воспроизводимой базовой линии (baseline) распознавания для рунического материала и в количественной характеристике синтетически-реального разрыва как величины, определяющей дальнейшие направления его сокращения.

3.2 Золотой стандарт (gold set)

Золотым стандартом (gold set) в работе называется компактное множество реальных фотографий рунических надписей с экспертно выверенной транслитерацией, используемое исключительно для валидации и тестирования. Его объём сознательно ограничен порядком нескольких десятков-сотен надписей: как показано в подразделе, большая выборка верифицированных пар недостижима без непропорциональных затрат ручной разметки, тогда как для несмещённой оценки переносимости модели и для типологического анализа ошибок выборки такого порядка достаточно при условии корректного учёта статистической погрешности.

Транслитерационные метки gold set полностью нормализуются к чистому графемно-транслитерационному ядру конвенции Rundata. Вся вспомогательная эпиграфическая разметка (индикаторы лакун, разделители, повреждения носителя) отсекается на этапе предобработки, формируя жесткую целевую последовательность (hard label), состоящую исключительно из знаков допустимого унифицированного алфавита.

В отличие от подходов, допускающих вероятностное сглаживание меток (soft labeling), в данной конфигурации пайплайна для каждой знаковой позиции на реальном носителе выбирается строго один целевой графемный класс, соответствующий наиболее аргументиро-

ванному консенсусному прочтению в базе данных Rundata. Документированные расхождения транслитераций между эпиграфическими школами выносятся за рамки графематического ядра модели; они фиксируются в изолированном «логе расхождений» и привлекаются исключительно на этапе качественного интертекстуального анализа ошибок, не влияя на расчет целевой функции потерь и метрики CER.

Разметка золотого стандарта организована иерархически на трёх уровнях, что обеспечивает совместимость с задачами компьютерного зрения и с последующим лингвистическим слоем и допускает повторное использование корпуса. Верхний уровень – надписи (*inscription*) – фиксирует метаданные памятника: внутренний идентификатор, географическую локализацию, датировку с указанием её точности, тип материала и состояние сохранности, руническую систему, библиографический источник и параметры съёмки (тип освещения, разрешение). Средний уровень – строки (*line*) – задаёт порядок и направление чтения и область строки на изображении. Нижний уровень – графемы (*glyph*) – содержит транслитерационную графему, помету аллографа (long-branch / short-twig / staveless), степень уверенности прочтения и, при наличии, множество альтернатив $\mathcal{A}_i$.

Таблица 3.1: Иерархическая схема аннотации золотого стандарта

Уровень	Единица	Поля разметки
Надпись	памятник (<i>inscription</i>)	, внутренний ID (RUN-XXXXXX), локализация, датировка и её точность, материал, сохранность, рунич. система, источник, параметры съёмки (освещение, разрешение)
Строка	строка / сегмент (<i>line</i>)	порядок и направление чтения, область строки на изображении
Графема	знак (<i>glyph</i>)	транслитерационная графема, аллограф, степень уверенности, множество альтернатив $\mathcal{A}_i$

Отбор изображений в золотой стандарт ведётся не пропорционально распределению корпуса, а с ориентацией на покрытие источников гетерогенности, порождающих доменный сдвиг: рунической системы (Старший, Младший, Англосаксонский футарк), типа носителя (камень, металл, кость) и условной градации сохранности. При этом ограниченность представленности редких систем явно фиксируется как предел покрытия золотого стандарта, а не как свойство модели.


Назначение gold set остаётся строго оценочным: он образует тестовое множество и не участвует ни в обучении, ни в подборе гиперпараметров, для которых используется отложенная синтетическая подвыборка; при необходимости честной ранней остановки из него может выделяться небольшая девелопмент-доля, не пересекающаяся с тестовой. Ограниченный



(a) надпись на металле



(b) надпись на камне



(c) надпись на камне

Рис. 3.1: Примеры данных из оценочной выборки (gold set)

объём множества прямо влияет на интерпретацию результатов: оценка CER на выборке такого порядка сопровождается широкими доверительными интервалами, в связи с чем в экспериментальной части она приводится с бутстрэп-оценкой погрешности и трактуется как индикативная, а не как точечная характеристика качества.

3.3 Синтетический корпус

Если золотой стандарт обеспечивает оценочный сигнал, то весь обучающий сигнал работа черпает из синтетического корпуса. Корпус должен одновременно удовлетворять двум требованиям, которые описаны в данной главе. Во-первых, лексическая достоверность: изображённые знаковые последовательности обязаны быть реальными руническими словами, а не случайными наборами графем, иначе распознаватель обучится на несуществующем распределении языка. Во-вторых, визуальная достоверность деградированного носителя: структурный, а не аддитивный характер шума требует, чтобы синтетическое изображение воспроизводило именно те признаки локального контраста и текстуры, на которых распознаватель учится отделять рез от фона. Первое требование удовлетворяется заимствованием лексики из реальных транслитерационных баз; второе – управляемым диффузионным синтезом с обуславливанием по контуру.

3.3.1 Лексическая основа: извлечение слов из реальных баз

Лексика синтетического корпуса извлекается из текстовых экспортов реальных рунических баз (записи, восходящие к Rundata, и сводка Gamla runor Кристера Хампа), что прямо реализует логику Dencker и др. [51]: транслитерация выступает выравнивающим сигналом, связывающим знак и его латинское соответствие. Колонка транслитераций токенизируется на отдельные слова по границам, заданным символами вне допустимого алфавита; сохраняются токены длиной от трёх до двадцати пяти знаков, целиком состоящие из символов чистого графемно-транслитерационного ядра конвенции Rundata. Каждое слово отображается в руническую строку полной обратимой таблицей соответствий, после чего тождество *трансли-*

тера́ция → *руны* → *транслитерация* проверяется на всём корпусе: совпадение по построению гарантирует, что метка-строка точна.

Чтобы отсеять разовый шум транскрипции, в корпус включаются лишь слова, встретившиеся не менее двух раз; их частоты задают распределение, из которого ведётся выборка с температурой 0,7, так что частотные слова представлены чаще, приближая статистику обучающей выборки к корпусной. Из слов собираются фразы длиной от одного до четырёх слов, разделяемые рунической точкой-разделителем (U+16EC, :), что воспроизводит характерное для каменных надписей разделение слов и снабжает распознаватель примерами межсловных границ.

3.3.2 Рендеринг рунической строки

Полученная руническая строка отрисовывается шрифтом Noto Sans Runic чёрным по белому на холсте 1024×1024 с автоматическим подбором кегля: размер шрифта понижается до тех пор, пока строка не уместится в рабочую область, а при невозможности уместить её в одну строку выполняется перенос на несколько строк. Небольшое горизонтальное дрожание положения вносит позиционную вариативность.

Здесь же фиксируется первое ограничение покрытия синтетического корпуса. Шрифт реализует кодовые позиции рунического блока Unicode, а кодпойнт не различает аллографы: одна позиция покрывает все графические варианты знака. Следовательно, синтетические глифы представляют единственное аллографическое семейство на кодпойнт и не воспроизводят полную вариативность long-branch / short-twig / staveless. Это сужение – самостоятельный источник синтетически-реального разрыва, и его расширение обсуждается как направление развития.

3.3.3 Выбор парадигмы синтеза и модальности обусловливания

Центральное проектное решение синтетического конвейера – способ превращения отрисованной строки в фотореалистичное изображение каменной надписи. Пространство возможных парадигм сводится к пяти, и их сопоставление по трём критериям – контроль над целевой меткой, реалистичность врезки знака и потребность в реальных данных целевого письма – сведено в таблицу 3.2.

Два подхода исключаются по построению. Свободный синтез text-to-image выдаёт фотореалистичную «руноподобную» поверхность, но не позволяет задать, какие именно руны будут изображены, а значит, не порождает известной метки и непригоден для супервизорного

обучения. GAN-синтез письма (линия ScrabbleGAN [55]) допускает обусловливание текстом, однако обучается на реальном корпусе целевого письма, отсутствие которого и составляет исходную проблему работы; для рунического материала с десятками реальных образцов такая модель неустойчива. Параметрический трёхмерный рендеринг знака, врезанного в смоделированную каменную поверхность с рандомизацией освещения и выветривания, даёт одновременно точную геометрию, реалистичную врезку и точную метку и служит эталоном в работе Derin и Uçar [13]; его недостаток – высокая инженерная стоимость построения трёхмерных ассетов, материалов и шейдеров выветривания, плохо совместимая с одиночной разработкой в условиях вычислительных ограничений.

Остаются два режима на основе предобученной латентной диффузии [53], не требующие дообучения под рунический скрипт и потому естественные для малоресурсной задачи. Они различаются по оси «точность геометрии – реалистичность врезки». В режиме inpainting отрисованные руны маскируются вместе с буфером дилатации, и генерация физически не затрагивает зону знака: геометрия штрихов сохраняется попиксельно, а метка точна, однако руны остаются плоскими отрисованными штрихами, скомпонованными с синтезированным фоном, и читаются скорее как «нанесённые поверх», нежели как врезанные, без собственных теней и рельефа. В режиме ControlNet [54] всё изображение, включая зону знака, синтезируется заново под управлением контурной карты, и руны выходят согласованно врезанными в камень с единым освещением и выветриванием. Однако в таком режиме возможны артефакты на изображениях в виде неправильного начертания одной или нескольких рун, хотя встречаются крайне редко. Такой метод требует ручной выборочной валидации. Также замечено, что появление нежелательных артефактов присуще изображениям с короткими текстами (3-4 символа). Работа использует один основной режим: ControlNet – по принципу обеспечения фотореалистичности врезки.

Внутри парадигмы ControlNet остаётся выбор модальности обусловливания. ControlNet допускает управление по различным картам признаков, и их пригодность для тонких штрихов руны существенно различается; сопоставление приведено в таблице.

Выбор Canny мотивирован тем, что руническая графема определяется прежде всего топологией своих штрихов – ствола и ветвей, – которую бинарная карта рёбер фиксирует чище всего: на контрастном рендере детектор Canny выделяет однозначные границы каждого штриха, задавая жёсткий структурный каркас. Остальные модальности уступают по характеру сигнала. Мягкие края HED размывают границы тонких штрихов и оставляют модели больше свободы переинтерпретации формы, усиливая геометрический дрейф; scribble сознательно эскизен и слишком свободен; lineart настроен на чистую иллюстративную графику и навязывает

чуждый домену прайор. Карты глубины и нормалей неинформативны для плоского рендера, у которого нет рельефа: чтобы задействовать их, пришлось бы синтезировать карту рельефа реза, что вынесено в направления развития. Семантическая сегментация оперирует классами регионов, а не линиями, и для штриховой структуры бесполезна. Особый случай – MLSD: руны действительно преимущественно прямолинейны (ствол и наклонные ветви), что делает детектор прямых отрезков внешне привлекательным, однако он отбрасывает кривые элементы и знак-разделитель и навязывает прайор архитектурных линий, тем самым систематически искажая графемный инвентарь. Таким образом, Canny оказывается единственной модальностью, сохраняющей точную топологию штриха при сохранении управляемости жёсткостью обусловливания.

Таблица 3.2: Сопоставление парадигм синтеза рунических изображений

Подход	Контроль метки		Реалистичность врезки	Нужны реальные данные письма	Итог
Text-to-image без управления	без	нет	высокая	нет	непригоден: прочтение не задаётся
GAN-синтез письма	пись-	да	средняя	да (корпус целевого письма)	непригоден: требует отсутствующего корпуса
Параметрический 3D-рендеринг		точный	высокая	нет	эталон, но высокая инженерная стоимость
Диффузия inpainting (маска рун)	+	точный	средняя	нет	рассмотрен, но не использован»
Диффузия ControlNet Canny	+	приближённый	высокая	нет	принят как основной режим

3.3.4 Конвейер SD3 + ControlNet Canny: параметры

Реализованный основной конвейер устроен следующим образом. Контрастный рендер переводится в карту рёбер детектором Canny с нижним и верхним порогами 50 и 150 и однопиксельной дилатацией, утолщающей рёбра до устойчивой к шумам ширины. Полученная карта используется как управляющее изображение для модели Stable Diffusion 3 Medium [80] с адаптером ControlNet InstantX/SD3-Controlnet-Canny [54]. Под ограничение видеопамати порядка 15,6 ГБ модель загружается в формате float16 с выгрузкой блоков на CPU (model offload) и с отключением третьего текстового энкодера (T5), не критичного для коротких, фиксированных промптов.

RIH:Y+RPI:NIP:PN+D



(a) Рендер (вход ControlNet)

(b) Canny


(c) Depth



(d) Lineart

(e) Mlsd

(f) Normalbae



(g) Scribble

(h) Softedge

Рис. 3.2: Примеры синтетических изображений в разных режимах генерации

Текстовое обусловливание задаётся неизменной парой промптов: положительный описывает глубоко врезаемые руны на тёмно-сером гранитном носителе с выветренной эродированной поверхностью при ровном рассеянном освещении в стилистике археологической макросъёмки, отрицательный подавляет полированные, шрифтовые, «фэнтезийные» и иллюстративные артефакты, а также наложенный текст и водяные знаки. Из-за лимита в 77 токенов в CLIP-архитектурах используются самые основные и важные характеристики. Число шагов диффузии – 28, шкала guidance – 7,0.

Ключевой управляющий параметр – сила обусловливания ControlNet, зафиксированная на значении 0,65. Его повышение приближает форму синтезированных рун к управляющей карте, понижение даёт более убедительную каменную поверхность ценой большего геометрического дрейфа. Значение 0,65 выбрано как рабочий компромисс между фотореалистичностью врезки и сохранением геометрии знака. Каждое изображение сохраняется вместе с меткой, генерация ведётся возобновляемыми пакетами с дозаписью таблицы меток, что позволяет наращивать корпус инкрементально в пределах вычислительного бюджета.

3.4 Предобработка изображений и протокол разбиения

3.4.1 Предобработка изображений

Принятая стратегия предобработки минимальна и сохраняет метку: поскольку деградация рунического носителя является структурным, а не аддитивным шумом, классические методы извлечения сигнала – бинаризация Otsu и Sauvola, выделение границ Canny – не используются как основные операции. Вместо этого эффективнее дообучить энкодер. Изображение приводится лишь к входному формату конкретной модели: процессор TrOCR масштабирует его к фиксированному квадратному разрешению в трёхканальном представлении, мультимодальная модель семейства Qwen-VL использует собственный препроцессор с динамическим разрешением. Цветовое представление сохраняется трёхканальным, несмотря на близкую к монохромной природу каменных снимков, поскольку предобученные энкодеры рассчитаны на RGB-вход.

Аугментация применяется только к синтетической обучающей выборке и носит дополняющий характер, так как основная вариативность уже внесена самим синтезом (текстура, выветривание, освещение). Используются ограниченные фотометрические преобразования, такие как: яркость, контраст, гамма, умеренное размытие и гауссов шум, а также небольшие перспективные искажения; геометрические преобразования ограничены так, чтобы не нарушать читаемость и валидность метки. Gold set, как отражение работы конвейера в реальных

условиях, не аугментируется.

Поскольку этап детекции в работе не используется, первичным входом распознавателя служит изображение надписи целиком. Разметка строкового уровня позволяет при необходимости подавать на вход вырезанные области строк, что особенно существенно для протяжённых надписей с дуговым и спиральным расположением знаков, образующих заведомо трудный случай и обсуждаемых среди ограничений работы.

3.4.2 Протокол разбиения и контроль утечки

Синтетический корпус делится на обучающую и валидационную подвыборки, причём разбиение производится по уникальным словам и фразам: лексическая непересекаемость синтетических train и val гарантирует, что валидация измеряет обобщение на не встречавшиеся строки, а не запоминание; синтетическая валидация используется для подбора гиперпараметров и ранней остановки. Реальный gold set целиком образует тестовое множество и не участвует ни в обучении, ни в подборе гиперпараметров. При необходимости честной ранней остановки из него может выделяться небольшая девелопмент-доля, не пересекающаяся с тестовой.

Отдельного внимания требует контроль лексической утечки между синтетическим обучением и реальным тестом. Поскольку и синтетическая лексика, и тексты gold set восходят к одним и тем же реальным базам, одно и то же слово может присутствовать в обоих, и без специальной меры оценка на gold set смешивала бы перенос на реальные носители с припоминанием уже виденной строки. Чтобы оценка отражала именно визуальный перенос, слова, входящие в gold set, исключаются из лексикона синтетического обучения.

4 Методология и архитектура

Работа намеренно сопоставляет два класса распознавателей, оба в сквозном (end-to-end) виде и оба адаптируемые параметрически эффективными методами на одном и том же синтетическом корпусе: специализированную OCR-модель TrOCR и мультимодальную модель общего назначения семейства Qwen-VL. Содержательный вопрос сопоставления состоит в следующем: переносится ли широкий зрительно-языковой прайор крупной универсальной модели на чуждый рунический домен лучше, чем специализированный, но меньший по размеру OCR-распознаватель, при равных обучающих данных и едином протоколе оценки.




Рис. 4.1: Общая схема конвейера

4.1 Постановка задачи и общая схема конвейера

Задача распознавания формализуется как отображение $f_\theta : \mathcal{I} \rightarrow \Sigma^*$, переводящее изображение надписи $I \in \mathcal{I}$ в строку транслитерации над фиксированным алфавитом Σ из 33 знаков чистого графемно-транслитерационного ядра конвенции Rundata. Отображение реализуется целиком, без промежуточного этапа детекции и классификации отдельных графем. Качество f_θ измеряется стандартным CER (4) на двух множествах: отложенной синтетической подвыборке и реальном gold set. Первое характеризует обучаемость на синтетическом распределении, второе — переносимость на реальные носители; их разность оценивает синтетически-реальный разрыв.

Принципиально, что для обеих архитектур целевой выход — это латинская строка транслитерации, а не последовательность кодовых позиций рунического блока Unicode. Это решение имеет прямое архитектурное следствие, общее для TrOCR и Qwen-VL: алфавит Σ целиком покрывается уже существующими субсловными словарями предобученных моделей, что устраняет необходимость расширять токенизатор рунами и позволяет переиспользовать предобученные текстовые представления без модификации — критическое преимущество в условиях малого объёма данных. Сводное сопоставление двух распознавателей приведено в таблице 4.1.

Переход к сквозному предсказанию строки снимает необходимость в явной system-aware голове классификатора для покомпонентной архитектуры: разрешение системной принадлежности и графемно-фонемная неоднозначность перекладываются на авторегрессивный языковой декодер, моделирующий целевую строку контекстно. Тем самым требование системной обусловленности не отменяется, а реализуется неявно — ценой потери интерпретируемости пографемной классификации, что обсуждается среди ограничений. Общая архитектура конвейера представлена на рисунке 4.1

Таблица 4.1: Сопоставление baseline распознавания

Свойство	TrOCR	Qwen-VL
Класс модели	специализированный OCR-распознаватель	мультимодальная модель общего назначения
Энкодер	визуальный трансформер (ViT / BEiT / DeiT)	визуальный трансформер с нативным динамическим разрешением
Декодер	текстовый трансформер (RoBERTa / MiniLM)	языковая модель Qwen (авторегрессивная)
Обработка входа	масштабирование к фиксированному квадрату	переменное разрешение, инструкция + изображение
Адаптация	LoRA (база заморожена)	QLoRA: 4-битная база + LoRA
Целевой выход	строка транслитерации (алфавит Σ)	строка транслитерации (алфавит Σ)
Испытанные размеры	базовый уровень (BASE)	2/4/8 млрд параметров
Роль в работе	специализированная базовая линия	универсальная базовая линия

4.2 Baseline 1: TrOCR с адаптацией LoRA

Первый baseline – модель TrOCR [6], объединяющая визуальный трансформерный энкодер (ViT / BEiT / DeiT) с авторегрессивным текстовым декодером (RoBERTa / MiniLM) и предобученная на масштабном двухступенчатом корпусе печатных и рукописных строк. Выбор TrOCR как специализированной линии мотивирован тем, что в литературе по историческому НТР она образует фактический стандарт и, что существеннее для малоресурсной задачи, допускает дообучение относительно небольшим числом размеченных строк [23, 29]. При этом сохраняется зафиксированная в обзоре оговорка: устойчивое превосходство над свёрточно-рекуррентными конвейерами демонстрирует прежде всего вариант LARGE [24], тогда как меньшие конфигурации могут уступать.

Адаптация выполняется методом LoRA [7]: в линейные проекции слоёв внимания и

сопутствующие полносвязные подслои внедряются обучаемые низкоранговые матрицы, тогда как исходные веса остаются замороженными. Это сокращает число обучаемых параметров на порядки, что одновременно снижает требования к видеопамяти и ограничивает переобучение на синтетическом распределении. Существенно, что адаптеры охватывают не только энкодер, но и декодер: как показано Parres и Paredes [25], при адаптации к новому языковому материалу замораживание декодера ведёт к потере нескольких процентных пунктов CER, поэтому адаптация только зрительной части в данной задаче недостаточна. Целевой алфавит Σ является подмножеством предобученного субсловного словаря, благодаря чему дообучение не требует расширения токенизатора. Обучение ведётся на синтетическом корпусе, отбор контрольной точки и ранняя остановка – по синтетической валидации с лексической непересекаемостью.

4.3 Baseline 2: мультимодальная модель Qwen-VL с адаптацией QLoRA

Второй baseline – мультимодальная модель семейства Qwen-VL [31], в которой визуальный энкодер преобразует изображение в последовательность зрительных токенов, подаваемых вместе с текстовой инструкцией в авторегрессивную языковую модель, генерирующую ответ. Архитектурно значимы две особенности. Во-первых, нативная поддержка переменного разрешения позволяет подавать изображение надписи без агрессивного масштабирования к фиксированному квадрату, что потенциально сохраняет мелкие детали штриха, критичные для различения аллографов. Во-вторых, задача задаётся инструкцией: модель получает изображение и предписание выдать транслитерацию в конвенции Rundata, а целевым выходом, как и для TrOCR, служит строка над алфавитом Σ .

Использование универсальной мультимодальной модели как распознавателя требует обоснования, поскольку систематические оценки показывают, что в режиме zero-shot такие модели массово проваливаются именно на редких скриптах, мелких символах и нестандартной композиции [36, 37] – всех трёх характеристиках рунической эпиграфики. Отсюда следует, что универсальная модель пригодна здесь не как готовый распознаватель, а как объект дообучения, и сопоставление с TrOCR ведётся именно в режиме адаптации. Адаптация выполняется методом QLoRA: базовая модель квантуется в 4-битное представление, а обучаемые низкоранговые адаптеры LoRA внедряются в проекции внимания языковой части. Квантование базовых весов снижает объём занимаемой видеопамяти настолько, что модель с семью миллиардами параметров уместается в бюджет порядка 15,6 ГБ, оставаясь обучаемой через адаптеры.

Ограниченность видеопамати задаёт единый принцип отбора моделей. Для каждого семейства выбирается наибольший вариант, чья пиковая память обучения не превосходит бюджета при фиксированных квантовании, ранге адаптеров, размере пакета и разрешении входа. Сообщаются все варианты, удовлетворяющие этому ограничению. В соответствии с этим критерием в работе испытаны конфигурации Qwen2-VL 2B, Qwen2.5-VL 7B, а также Qwen3-VL 2B, 8B.

4.4 Демонстрационный модуль автоматического перевода

Распознающий конвейер завершается транслитерацией. Этот выход является не конечным результатом для пользователя, а промежуточным представлением, пригодным для дальнейшей лингвистической обработки. Чтобы продемонстрировать сквозную работу всей цепочки «изображение надписи $\rightarrow$ транслитерация $\rightarrow$ смысл», транслитерация подаётся на вход модуля автоматического перевода на современный язык. Сам перевод рунических текстов составляет предмет отдельного исследования, выполненного в рамках смежной работы [17, 18], и не относится к собственному вкладу настоящей работы. Здесь он привлекается как демонстрационное завершение конвейера, показывающее, что выход распознавателя совместим с последующим переводческим слоем.

Принцип модуля состоит в дообучении предобученной большой языковой модели (Large Language Model, LLM) на параллельном корпусе под задачу перевода рунической транслитерации. По данным [17], для обучения собран параллельный корпус объёмом около 8,2 тыс. пар «транслитерация – перевод», извлечённых из баз Rundata, RuneS и сводки Gamla runor Кристера Хампа и охватывающих три целевых языка – английский, немецкий и шведский. Перед подачей в модель транслитерация нормализуется к латинице с разворачиванием специальных графем ($\text{þ} \rightarrow \text{th}$, $\text{ð} \rightarrow \text{d}$, $\text{æ} \rightarrow \text{ae}$), приведением к нижнему регистру и удалением разметочных символов. Адаптация выполняется методом LoRA (ранг $r = 16$, масштаб $\alpha = 32$, dropout 0,05) с внедрением низкоранговых матриц в проекции query и value слоёв внимания; обучение ведётся средствами библиотек Unsloth и TRL (размер пакета 16, скорость обучения 2×10^{-4} , 20 эпох, оптимизатор AdamW с косинусным затуханием скорости, максимальная длина последовательности 512), трекинг экспериментов – в ClearML, инференс – через Ollama, а качество измеряется метриками BLEU, chrF и chrF++.

Наиболее удачный из проведённых экспериментов сведён в таблицу 4.2. По данным [17], дообучение даёт кратный прирост качества относительно базовых моделей, для которых перевод рунической транслитерации практически недоступен (BLEU порядка единиц, на-

пример 2,31 у меньшей модели семейства Qwen на английском). После адаптации лучшая по английскому и немецкому языкам конфигурация Gemma-2-2B достигает BLEU 55,93 и chrF++ 67,77 на английском и BLEU 48,00 на немецком, тогда как для шведского языка наилучший результат – BLEU 38,53 – показывает большая по размеру модель семейства Qwen. Качественно эффект адаптации проявляется в переходе от бессвязного набора слов к грамматически корректному мемориальному тексту: так, надпись Йеллингского камня базовая модель переводит как несвязное перечисление, а дообученная – как «*King Haraldr ordered these monuments made in memory of Gormr, his father, and in memory of þyrvé, his mother*», с корректной передачей имён собственных и характерной формульной структуры мемориальной надписи.

Таблица 4.2: Лучшие результаты демонстрационного модуля перевода (по данным [17])

Целевой язык	Лучшая конфигурация	BLEU	chrF++
Английский	Gemma-2-2B + LoRA (20 эпох)	55,93	67,77
Немецкий	Gemma-2-2B + LoRA (20 эпох)	48,00	64,36
Шведский	Qwen2.5-3B + LoRA	38,53	57,56

Сопряжение модуля перевода с распознавателем требует тонкого нормализующего адаптера. Распознаватель порождает транслитерацию в конвенции Rundata, где þ, , æ и ø сохраняются как самостоятельные графемы (подраздел 2.4), тогда как переводческий модуль ожидает их развёрнутого латинского представления; согласование двух нотаций выполняется детерминированным преобразованием на стыке модулей. Существенно, что в исходном исследовании [17] перевод оценивался на эталонных экспертных транслитерациях, а в сквозной демонстрации он получает на вход результат распознавания, неизбежно содержащий ошибки. Поэтому посимвольные ошибки распознавателя распространяются в переводческий слой и складываются с собственной погрешностью перевода; именно по этой причине модуль позиционируется как демонстрационный, а не как самостоятельно оцениваемая сквозная переводческая система.

Промежуточный вывод. Подключение переводческого модуля показывает, что транслитерация, порождаемая распознавателем, образует корректный интерфейс к последующему лингвистическому анализу, и тем самым замыкает заявленную цепочку «распознавание – перевод». Количественная оценка сквозного качества, учитывающая совместное накопление ошибок распознавания и перевода, выходит за рамки настоящей работы и обозначается как направление дальнейшего исследования.

4.5 Протокол обучения и инфраструктура

Все эксперименты выполняются на единственном графическом ускорителе с объёмом видеопамати порядка 15,6 ГБ в средах Colab / Kaggle, что и определяет выбранные решения. Вычисления ведутся в смешанной точности (bf16 / fp16); базовые веса Qwen-VL хранятся в 4-битном представлении (NF4). Конфигурация LoRA – ранг, масштабирующий коэффициент, dropout и множество целевых модулей – приводится в репрезентативных пределах, а её итоговые значения, как и значения скорости обучения, числа эпох и эффективного размера пакета фиксируются в экспериментальной части. Оптимизатор – AdamW; ранняя остановка и отбор контрольной точки – по синтетической валидации. Прогон каждой конфигурации сопровождается логированием гиперпараметров, кривых обучения и метрик в систему трекинга экспериментов и фиксацией начальных состояний генераторов случайных чисел ради воспроизводимости. Единообразие протокола между TrOCR и Qwen-VL – один и тот же обучающий корпус, одна и та же синтетическая валидация, один и тот же тестовый gold set и единая метрика CER – обеспечивает корректность сравнения двух классов моделей.¹

5 Экспериментальная часть

Настоящая глава эмпирически проверяет центральное сопоставление: переносит ли широкий зрительно-языковой прайор крупной мультимодальной модели чуждый рунический домен лучше, чем специализированный распознаватель печатного и рукописного текста TrOCR, при обучении исключительно на синтетике и едином протоколе оценки. В соответствии со стратегией разделения сигналов все модели обучаются на синтетическом корпусе, а оцениваются на отложенной синтетической подвыборке и на реальном золотом множестве. Разность качества между ними образует центральную измеряемую величину работы – синтетически-реальный разрыв. Ввиду малого объёма gold set все оценки на нём сопровождаются бутстрэп-интервалами и трактуются как индикативные.

5.1 Протокол оценки и метрики

Основной метрикой служит посимвольная доля ошибок CER (3); в реализованной конфигурации используется стандартный CER, тогда как ambiguity-aware-расширение (4) остаётся методологическим заделом. В дополнение приводятся три вспомогательные метрики.

¹Исходный код конвейера (генерация синтетических данных, обучение и оценка моделей) доступен в репозитории: <https://github.com/kekys778/RUNIC-OCR> (дата обращения: 03.06.2026).

Пословная доля ошибок (Word Error Rate, WER) рассчитывается аналогично CER на уровне слов:

$$\text{WER} = \frac{S_w + D_w + I_w}{N_w}, \quad (5)$$

где S_w , D_w , I_w – числа замен, удалений и вставок слов, N_w – число слов в эталоне. Нормализованное редакционное расстояние (Normalised Edit Distance, NED) усредняет по корпусу расстояние Левенштейна, отнесённое к длине эталона:

$$\text{NED} = \frac{1}{M} \sum_{m=1}^M \frac{\text{Lev}(\hat{y}^{(m)}, y^{(m)})}{|y^{(m)}|}, \quad (6)$$

где M – число надписей. Доля точно распознанных строк (sequence accuracy) есть доля надписей с полным посимвольным совпадением предсказания и эталона.

Оценка проводится на двух множествах: отложенной синтетической подвыборке (215 строк) и реальном gold set (113 строк реальных надписей). Ввиду малого объёма gold set для CER на нём приводится 95 %-й перцентильный бутстрэп-интервал. Все прогоны выполнены в единой среде (одиночный ускоритель NVIDIA T4, смешанная точность, фиксированные начальные состояния), а единство обучающего корпуса, валидации и метрики обеспечивает корректность сравнения. Поскольку CER предсказания может превышать 100 %, когда суммарная длина вставок, удалений и замен превышает длину эталона, значения выше 100 % интерпретируются как полная несостоятельность распознавания.

5.2 Конфигурации моделей и состав данных

Сопоставляются специализированный распознаватель TrOCR (конфигурации BASE и LARGE) и мультимодальные модели семейств Qwen2-VL, Qwen2.5-VL и Qwen3-VL размером от 2 до 8 млрд параметров. Обучающий синтетический корпус, сформированный конвейером SD3 + ControlNet, содержит около 4,6 тыс. изображений; из него исключены 38 строк, чья транслитерация совпадала с лексиконом gold set, что предотвращает утечку, после чего корпус разделён на обучающую (4432) и валидационную (215) подвыборки. Реальное золотое множество составляет 113 строк надписей с экспертными транслитерациями.

Адаптация мультимодальных моделей выполнена методом QLoRA (4-битная квантизация базовой модели в сочетании с LoRA-адаптерами), а TrOCR – методом LoRA; общие гиперпараметры приведены в таблице 5.1, различающиеся между семействами – в таблице 5.2.

Таблица 5.1: Общие гиперпараметры обучения

Гиперпараметр	Значение
Доля обучаемых параметров	$\approx 0,81\text{--}0,83\%$
Ранг адаптеров r / масштаб α / dropout	16 / 32 / 0,05
Эффективный размер пакета	16
Отбор чекпойнта	по валидационному функционалу
Оборудование	одиночный NVIDIA T4, смешанная точность

Таблица 5.2: Гиперпараметры, различающиеся между моделями

Гиперпараметр	TrOCR	Qwen-VL
Метод адаптации	LoRA	QLoRA (4-битная квантизация + LoRA)
Целевые модули	q_proj, k_proj, v_proj, out_proj, query, key, value, up_proj, down_proj, dense	q_proj, k_proj, v_proj, o_proj, gate_proj, up_proj, down_proj
Скорость обучения	$5 \cdot 10^{-5}$ (BASE), $3 \cdot 10^{-5}$ (LARGE)	$1 \cdot 10^{-4}$
Размер пакета на устройство	8 (BASE), 4 (LARGE)	1
Gradient accumulation	2 (BASE), 4 (LARGE)	16
Число эпох	25	3
Оптимизатор	AdamW	PagedAdamW 8-bit
Gradient checkpointing	нет	да

5.3 Качество моделей без адаптации

Базовую линию образует качество предобученных моделей без дообучения на рунической задаче (zero-shot). Результаты сведены в таблицу 5.3. Все модели демонстрируют полную несостоятельность: CER на gold set превышает 100 %, а характер ошибок указывает на отсутствие у моделей представления о рунической транслитерации. Специализированные TrOCR-BASE и TrOCR-LARGE, предобученные на печатных и рукописных латинских строках, порождают английские слова и фрагменты («SURGEON GENERAL’S», «MATERIAL»), интерпретируя руническое изображение как искажённый латинский текст. Мультимодальные модели без адаптации генерируют пространные англоязычные комментарии вида «The runic inscription in the image is. . . » и вырожденные повторяющиеся последовательности, что типично для зрительно-языковых моделей вне их обучающего распределения и объясняет экстремальные значения CER (до 724 % у Qwen2-VL-2B).

Таблица 5.3: Качество моделей без адаптации (zero-shot), оценка на gold set, %

Модель	CER, синт.	CER, gold	(95 % ДИ)	WER
TrOCR-BASE-334M	119,95	103,79	101,9–106,0	112,35
TrOCR-LARGE-558M	250,76	100,53	99,7–101,4	107,65
Qwen2-VL-2B	337,42	724,55	594,4–889,5	848,24
Qwen2.5-VL-7B	99,18	102,74	99,9–106,3	103,53
Qwen3-VL-2B	218,10	364,81	310,7–426,4	422,94
Qwen3-VL-8B	168,49	237,93	193,4–286,6	124,12

Дополнительно, в порядке качественной проверки, через веб-интерфейс на ограниченной выборке надписей протестированы ведущие современные проприетарные мультимодальные модели общего назначения – Claude Opus 4.6, ChatGPT 5.2 и Grok-3. Поскольку программный доступ (API) к этим моделям в рамках работы был недоступен, обращение выполнялось вручную через браузерное окно, а количественные метрики для них не вычислялись. По той же причине эти модели не могли быть дообучены и фигурируют только в zero-shot-сопоставлении. Несмотря на ограничения, можно сделать вывод, что одна из протестированных моделей не смогла корректно распознать руническую надпись по изображению и выдать правильную транслитерацию. Тем самым качественная проверка согласуется с количественными результатами таблицы 5.3: недоступность задачи в режиме zero-shot не является артефактом выбора конкретных открытых моделей, а распространяется и на сильнейшие доступные на момент исследования системы.

5.4 Результаты после дообучения на синтетике

Дообучение на синтетическом корпусе качественно меняет картину. Сводные результаты приведены в таблице 5.4. Все модели показывают кратное снижение CER на gold set относительно zero-shot: для Qwen2-VL-2B – с 724,55 % до 73,97 %, для Qwen3-VL-2B – с 364,81 % до 73,55 %. Наилучший результат принадлежит Qwen2.5-VL-7B: модель, показавшая наименьшую ошибку уже в zero-shot (102,74 %), после дообучения достигает CER 54,27 % (95 % ДИ 48,0–61,3) на gold set – то есть более чем вдвое лучше необученного состояния и заметно лучше всех прочих конфигураций. Преимущество статистически значимо: доверительный интервал Qwen2.5-VL-7B не пересекается ни с интервалом более крупной Qwen3-VL-8B (62,2–73,6), ни с интервалами моделей размером 2 млрд (69,9–77,5).

Таблица 5.4: Качество после дообучения (обучение на синтетике, оценка на gold set), %

Модель	CER, синт.	CER, gold	(95 % ДИ)	WER	SeqAcc	Δ CER
TrOCR-BASE-332M	28,40	93,75	93,0–95,1	100,0	0,0	+65,35
TrOCR-LARGE-558M	14,27	95,05	93,9–96,1	100,0	0,0	+80,78
Qwen2-VL-2B	41,70	73,97	70,5–77,5	98,24	0,88	+32,27
Qwen2.5-VL-7B	12,03	54,27	48,0–61,3	81,18	8,85	+42,24
Qwen3-VL-2B	33,39	73,55	69,9–77,5	97,65	1,77	+40,16
Qwen3-VL-8B	34,69	67,86	62,2–73,6	95,29	0,88	+33,17

На основе данных таблицы 5.4 можно сделать три ключевых вывода. Во-первых, увеличение масштаба модели в рамках одного семейства положительно влияет на качество генерализации. Так, переход от Qwen3-VL-2B к Qwen3-VL-8B снижает значение CER на валидационной выборке (gold set) с 73,55 до 67,86 % и сокращает доменный разрыв между синтетическими и реальными данными с +40,2 до +33,2 п.п. Тем не менее наилучший результат демонстрирует не самая крупная архитектура: модель Qwen2.5-VL-7B (54,27 %) существенно превосходит более позднюю Qwen3-VL-8B (67,86 %). Таким образом, применение более современных архитектур не обеспечивает гарантированного прироста качества при работе в узкоспециализированных доменах. Во-вторых, значительный разрыв в точности на синтетическом и реальном доменах характерен для всех протестированных конфигураций. Модели эффективно подстраиваются под синтетическое распределение (CER на синтетической валидации составляет всего 12–42 %), однако при переносе на реальные носители метрики значимо ухудшаются (CER на gold set возрастает до 54–74 %). Это указывает на то, что главным источником ошибок является именно доменный сдвиг, а не недостаточная емкость или недообученность моделей. В-третьих, общая доля полностью распознанных строк (Exact

Match) остается низкой для всей выборки, однако у наиболее эффективной конфигурации она заметно выше — 8,85 % против 0,9–1,8 % у остальных. Это свидетельствует о том, что Qwen2.5-VL-7B способна обеспечивать абсолютно корректное прочтение коротких надписей существенно чаще других рассматриваемых моделей.

Особенно показательно поведение моделей семейства TrOCR. После дообучения TrOCR-LARGE осваивает синтетическое распределение лучше большинства мультимодальных моделей (CER на синтетике 14,27 %, близко к 12,03 % у Qwen2.5-VL-7B), однако на реальных носителях его выход коллапсирует: модель порождает один и тот же короткий токен (**ek**) почти для всех надписей, давая CER на gold set 95,05 % и наибольший синтетически-реальный разрыв (+80,78 п. п.); TrOCR-BASE ведёт себя аналогично (28,40 % на синтетике против 93,75 % на gold set). Это означает, что узкий OCR-декодер, предобученный как языковая модель латинского текста, переобучается на синтетику и не переносит выученное на реальную доменную вариативность. Напротив, мультимодальные модели при сопоставимой или даже лучшей подгонке к синтетике сохраняют работоспособность на реальных данных. Тем самым центральное сопоставление работы разрешается в пользу мультимодальных моделей: при сопоставимой подгонке к синтетике широкий зрительно-языковой прайор обеспечивает перенос на реальные носители, а специализированная OCR-архитектура – нет.

5.5 Анализ ошибок

Анализ ошибок проведён качественно по выдаче лучшей модели (Qwen2.5-VL-7B), поскольку автоматический подсчёт типов ошибок и матрица смещения графем в данном прогоне не вычислялись; их формирование вынесено в перспективы. Репрезентативные примеры приведены в таблице 5.5.

Таблица 5.5: Примеры распознавания (Qwen2.5-VL-7B): эталон и предсказание

Эталон	Предсказание	
stain	stain	✓
karpi	karpi	✓
raist	raist	✓
auk	auk	✓
karpi kuml pusi eftiR urmar	karpi kuml pus eftiR	
	urma	
raisa stain	rasa stain	
tir	ek	
haeramalausR	alu	

Из выдачи прослеживаются три устойчивые тенденции. Во-первых, короткие частотные единицы мемориальных надписей распознаются точно (**stain**, **karpi**, **raist**, **auk**), а на

протяжённых надписях формульная структура восстанавливается почти полностью: в самой длинной надписи корпуса корректно воспроизводятся ключевые слова мемориальной формулы (*karþi kuml þus eftiR urma* при эталоне *karþi kuml þusi eftiR urmar*). Качество на длинных формульных надписях заметно выше, чем у меньших моделей, что согласуется как с преобладанием мемориальных формул и имён собственных в обучающем материале, так и с более сильным переносом крупной мультимодальной модели.

Во-вторых, доминируют замены графически и фонетически близких рун – смычных и сонорных в парах *k / g*, *t / þ*, *b / þ*, гласных *i / e* и *u / o*, а также *R / r* и *m / n*. Эти смещения отражают не случайный сбой, а графемно-фонемную близость, о которой также говорилось в работе, и сохранение в алфавите Σ противопоставлений (*R* против *r*), различение которых требует тонких начертательных признаков.

В-третьих, на части коротких и более архаичных надписей наблюдается отказ: вместо содержательного прочтения модель порождает частотную последовательность по умолчанию – *ek* или *alu*, многократно встречающееся в корпусе, – что завышает WER при умеренном CER. Для сравнения, в режиме без адаптации преобладали качественно иные сбои – вырожденные повторы и англоязычные галлюцинации. Их исчезновение после дообучения подтверждает, что адаптация переводит модель в режим порождения рунической транслитерации, а остаточные ошибки имеют уже доменную, а не категориальную природу.

Следует заключить, что ошибки разделяются на два вида: устранимые средствами расширения синтеза и трудноустраняемые в графемной постановке, что прямо определяет приоритеты дальнейшей работы: сокращение синтетически-реального разрыва и обогащение аллографического покрытия обучающего корпуса.

5.6 Соотнесение с гипотезой и границы применимости

Полученные результаты позволяют дать прямой ответ на исследовательский вопрос работы. Лучшая конфигурация (Qwen2.5-VL-7B) достигает на реальном gold set CER 54,27 % (95 % ДИ 48,0–61,3), что существенно выше условного порога практической применимости в 20 %. Соответственно, рабочая гипотеза о достижимости практически приемлемого качества распознавания (CER < 20 %) при обучении исключительно на синтетике **не подтверждается** в данной постановке: достигнутый уровень переноса остаётся недостаточным для автономной транслитерации.

Вместе с тем вклад экспериментальной части не сводится к недостижению порога. Во-первых, установлена первая воспроизводимая базовая линия распознавания для скан-

динавского рунического материала, причём дообучение на синтетике улучшает качество относительно zero-shot кратно (с 102–724 % до 54–74 % CER у работоспособных моделей). Во-вторых, количественно охарактеризован синтетически-реальный разрыв (+32–+42 п. п.) как доминирующий источник ошибки и, тем самым, как основная направленность для дальнейшей доменной адаптации. В-третьих, показано, что выбор зрительно-языковой модели определяется не только её размером, а специализированный латинский OCR (TrOCR), несмотря на хорошую подгонку к синтетике, коллапсирует на реальных данных и для рунической транслитерации непригоден.

Границы применимости системы очерчиваются достигнутым качеством: выход модели пригоден для предварительной, поддерживаемой экспертом обработки и частичного восстановления частотных формульных элементов, но не для окончательной автоматической транслитерации. Полученный результат требует последующей экспертной корректуры.

6 Обсуждение, ограничения и направления дальнейшей работы

6.1 Обсуждение результатов

Полученные результаты подтверждают исходную постановку проблемы и одновременно уточняют её. Эксперименты продемонстрировали, что задача распознавания рунической транслитерации недоступна предобученным моделям без адаптации, но становится разрешимой при дообучении на синтезируемых данных: лучшая конфигурация снижает CER на реальном gold set с 102,74 % в режиме zero-shot до 54,27 %. Тем самым центральная гипотеза о практической приемлемости ($CER < 20\%$) не подтверждается, однако работа решает заявленную методологическую задачу – демонстрирует, что обучение исключительно на синтетике обеспечивает работоспособный, хотя и не финальный, перенос на реальные носители.

Главным содержательным выводом является характер доминирующей ошибки. Все работоспособные модели уверенно осваивают синтетическое распределение, но систематически теряют качество на реальных носителях. Измеренный синтетически-реальный разрыв в +32–+42 п. п. и есть основное препятствие, отделяющее достигнутый результат от практического порога. Это смещает фокус дальнейшей работы с архитектуры распознавателя на сокращение доменного сдвига между синтетическим и реальным распределениями.

Сравнение архитектур дало нетривиальный результат. Специализированный распознаватель TrOCR, несмотря на почти эталонное распознавание на синтетике, коллапсирует на

реальных данных, вырождая выход в постоянный токен, – то есть переобучается на синтетическое распределение и не переносит выученное. Мультимодальные модели при сопоставимой подгонке сохраняют работоспособность, что подтверждает гипотезу о ценности широкого зрительно-языкового прайора для малоресурсного исторического скрипта.

6.2 Ограничения исследования

Результаты работы следует интерпретировать в пределах ряда ограничений, часть которых соответствует ключевым проблемам, поставленным во введении.

Объём реальных данных остаётся критически малым. Реальное золотое множество включает лишь 113 строк, поэтому оценки на нём индикативны: доверительные интервалы CER широки, а разбиение качества по срезам (руническая система, материал носителя, степень сохранности) в настоящей работе не вычислялось и потому не характеризуется количественно.

Синтетически-реальный разрыв не закрыт. Обучение проводилось исключительно на синтетике, реальный обучающий материал не использовался, а методы доменной адаптации в обучающий конвейер не включались.

Эпиграфическая неоднозначность учтена лишь теоретически. Формализм мягкой разметки и ambiguity-aware-метрики A-CER изложен в теоретической части, однако в реализации принята жёсткая разметка и стандартный CER. Вероятностное представление допустимых альтернативных прочтений не реализовано, поскольку требует экспертно-размеченного множества альтернатив.

Межсистемный и межскриптовый перенос не измерен отдельно. Использована единая модель над общим алфавитом Σ , а gold set не стратифицирован по системам письма (Старший футарк, Младший футарк, англосаксонский футорк), поэтому различие в качестве распознавания между диахронически и регионально разнородными системами осталось за рамками количественной оценки.

Аллографическое покрытие синтеза ограничено. Генератор воспроизводит по одному характерному начертанию на кодпойнт, вследствие чего не представленные в обучении аллографические варианты заведомо распознаются хуже, что подтверждается анализом ошибок.

Анализ ошибок носит качественный характер. Автоматическая матрица смещения графем и метрики по срезам не вычислялись, а наблюдаемые тенденции замен установлены по выдаче лучшей модели, а не по полной статистике корпуса.

Перевод реализован как демонстрационный модуль на основе смежного исследования.

Сквозное качество цепочки «распознавание → перевод», учитывающее совместное накопление ошибок, не оценивалось, а сам порог практической применимости в 20 % принят как инженерная граница и не валидирован эмпирически.

6.3 Направления дальнейшей работы

Из перечисленных ограничений вытекают возможные дальнейшие шаги.

Первоочередной задачей является сокращение синтетически-реального разрыва как доминирующего источника ошибки. Перспективны методы доменной адаптации, в том числе доменно-сопоставительное обучение с градиентным разворотом (DANN), дообучение на небольшом объёме реальных размеченных надписей (few-shot), смешанные обучающие выборки синтетики и реальных данных, а также повышение реалистичности синтеза за счёт более точного моделирования текстуры и деградации поверхности (включая модальности RTI и фотограмметрии).

Второе направление – расширение и стратификация эмпирической базы: увеличение объёма реального золотого множества и его разбиение по руническим системам, материалам и степени сохранности, что позволит количественно измерить межсистемный перенос и зависимость качества от условий съёмки.

Третье направление – реализация вероятностной разметки: формирование экспертно-размеченного множества альтернативных прочтений и обучение с мягкими метками с оценкой по A-CER, что переведёт учёт эпиграфической неоднозначности из теоретической плоскости в практическую.

К дальнейшим задачам относятся также обогащение аллографического покрытия синтетического корпуса, проведение полного количественного анализа ошибок, абляционное исследование вклада отдельных компонентов конвейера (режим синтеза, аугментация, фильтр согласованности) и сквозная оценка качества цепочки «распознавание → перевод».

Отдельную перспективу образует развитие сформированного корпуса в инфраструктуру более высокого уровня. Совмещение в единой структуре изображений, транслитераций, нормализованных форм и метаданных делает корпус естественной основой для построения набора данных типа «визуальный вопрос – ответ» (Visual Question Answering, VQA) по руническим артефактам и, в перспективе, для создания полнофункционального цифрового ассистента германиста, историка и археолога.

Заключение

Настоящая работа посвящена автоматическому распознаванию древнегерманских рунических надписей в условиях критически малого объёма реальных данных. Центральным исследовательским вопросом являлось то, в какой мере обучение исключительно на управляемо синтезируемой выборке переносится на реальные носители и насколько близко достижимое при таком переносе качество подходит к условному порогу практической применимости.

Для ответа на этот вопрос разработан сквозной конвейер. Текстовые ресурсы рунических баз данных (Rundata, RuneS) служат источником транслитерационной лексики, на их основе средствами латентной диффузии с пространственным обусловливанием (SD3 в сочетании с ControlNet) и врезкой (Canny) синтезируется обучающий корпус рунических изображений, проходящий фотометрическую аугментацию. На этапе вывода реальная фотография надписи проходит минимальную нормализацию входа и подаётся в распознаватель, дообученный методами LoRA и QLoRA. Распознаватель порождает латинскую транслитерацию в конвенции Rundata над алфавитом Σ . Эта транслитерация образует интерфейс к последующей лингвистической обработке: в работе она передаётся демонстрационному модулю автоматического перевода, а её качество оценивается посимвольной метрикой CER на реальном золотом множестве с разделением синтетического и реального распределений.

Эмпирическая проверка дала следующие основные результаты. Без доменной адаптации задача недоступна ни специализированному распознавателю TrOCR, ни крупным мультимодальным моделям: посимвольная ошибка в режиме zero-shot превышает 100 %. Дообучение на синтетике кратно улучшает качество, и лучшая конфигурация – Qwen2.5-VL-7B – достигает CER 54,27 % на реальном gold set. Тем самым установленный условный порог CER < 20 % не достигнут, однако установлено, что доминирующим препятствием выступает не архитектура распознавателя, а синтетически-реальный разрыв. Показано также, что широкий зрительно-языковой прайор мультимодальной модели обеспечивает перенос на реальные носители, тогда как специализированный латинский OCR при хорошей подгонке к синтетике коллапсирует, и что выбор модели определяется её версией и качеством предобучения не в меньшей степени, чем размером.

Научные результаты работы состоят в следующем. Предложен и реализован сквозной конвейер распознавания рунической транслитерации с обучением исключительно на синтетических данных. Сформированы аннотированный мультимодальный синтетический корпус и корпус реальных изображений с унифицированной схемой разметки и контролем лексической непересекаемости. Выполнена адаптация современных архитектур HTR/OCR и зрительно-

языковых моделей к специфике исторических рунических надписей. Проведён сравнительный анализ специализированного OCR-подхода и мультимодальных моделей, установивший преимущество последних в малоресурсном сценарии. Наконец, формализован аппарат учёта эпиграфической неоднозначности (мягкая разметка, метрика A-CER).

Практическая значимость полученных результатов связана с сокращением временного разрыва между обнаружением рунического памятника и его первичным содержательным анализом. Разработанный конвейер позволяет автоматизировать наиболее трудоёмкий этап предварительной обработки материала — переход от изображения надписи к её транслитерации и ориентировочной интерпретации, что создаёт дополнительные возможности для археологических, музейных и историко-культурных исследований. Сформированные корпус и программная инфраструктура могут служить основой для дальнейшего развития инструментов цифровой рунологии, включая специализированные наборы данных, системы визуального вопросно-ответного взаимодействия и интеллектуальных ассистентов для работы с памятниками германской письменности.

Список литературы

- [1] Yannis Assael, Thea Sommerschild и Jonathan Prag. «Restoring ancient text using deep learning: a case study on Greek epigraphy». В: *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*. 2019, с. 6369—6376. DOI: [10.18653/v1/D19-1668](https://doi.org/10.18653/v1/D19-1668).
- [2] Yannis Assael, Thea Sommerschild, Brendan Shillingford, Mahyar Bordbar, John Pavlopoulos, Marita Chatzipanagiotou, Ion Androutsopoulos, Jonathan Prag и Nando de Freitas. «Restoring and attributing ancient texts using deep neural networks». В: *Nature* 603.7900 (2022), с. 280—283. DOI: [10.1038/s41586-022-04448-z](https://doi.org/10.1038/s41586-022-04448-z).
- [3] Yannis Assael, Thea Sommerschild, Alison Cooley, Brendan Shillingford, John Pavlopoulos, Priyanka Suresh, Bailey Herms, John Grayston, Beth Maynard, Nicholas Dietrich, Robbe Wulgaert, Jonathan Prag, Alex Mullen и Shakir Mohamed. «Contextualizing ancient texts with generative neural networks». В: *Nature* 645.8079 (2025), с. 141—147. DOI: [10.1038/s41586-025-09292-5](https://doi.org/10.1038/s41586-025-09292-5).
- [4] Thea Sommerschild, Yannis Assael, John Pavlopoulos, Vanessa Stefanak, Andrew Senior, Chris Dyer, John Bodel, Jonathan Prag, Ion Androutsopoulos и Nando de Freitas. «Machine Learning for Ancient Languages: A Survey». В: *Computational Linguistics* 49.3 (2023), с. 703—747. DOI: [10.1162/coli_a_00481](https://doi.org/10.1162/coli_a_00481).
- [5] Elisabeth M. Magin и Marcus Smith. «(R)Unicode: Encoding and Sustainability Issues in Runology». В: *Digital Humanities in the Nordic and Baltic Countries Publications* 5.1 (2024), с. 121—136. DOI: [10.5617/dhnbpub.10657](https://doi.org/10.5617/dhnbpub.10657).
- [6] Minghao Li, Tengchao Lv, Jingye Chen, Lei Cui, Yijuan Lu, Dinei Florencio, Cha Zhang, Zhoujun Li и Furu Wei. «TrOCR: Transformer-Based Optical Character Recognition with Pre-trained Models». В: *Proceedings of the AAAI Conference on Artificial Intelligence* 37.11 (2023), с. 13094—13102. DOI: [10.1609/aaai.v37i11.26538](https://doi.org/10.1609/aaai.v37i11.26538).
- [7] Edward J. Hu, Yelong Shen, Phillip Wallis, Zeyuan Allen-Zhu, Yuanzhi Li, Shean Wang, Lu Wang и Weizhu Chen. «LoRA: Low-Rank Adaptation of Large Language Models». В: *International Conference on Learning Representations (ICLR)*. 2022. arXiv: [2106.09685](https://arxiv.org/abs/2106.09685).
- [8] Shai Gordin, Gai Gutherz, Ariel Elazary, Avital Romach, Enrique Jiménez, Jonathan Berant и Yoram Cohen. «Reading Akkadian cuneiform using natural language processing». В: *PLOS ONE* 15.10 (2020), e0240511. DOI: [10.1371/journal.pone.0240511](https://doi.org/10.1371/journal.pone.0240511).

- [9] Ethan Fetaya, Yonatan Lifshitz, Elad Aaron и Shai Gordin. «Restoration of fragmentary Babylonian texts using recurrent neural networks». B: *Proceedings of the National Academy of Sciences of the USA* 117.37 (2020), с. 22743—22751. DOI: [10.1073/pnas.2003794117](https://doi.org/10.1073/pnas.2003794117).
- [10] Edward C. Williams, Grace Su, Sandra R. Schloen, Miller C. Prosser, Susanne Paulus и Sanjay Krishnan. «DeepScribe: Localization and Classification of Elamite Cuneiform Signs Via Deep Learning». B: *ACM Journal on Computing and Cultural Heritage* 18.2 (2025), с. 31. DOI: [10.1145/3716850](https://doi.org/10.1145/3716850).
- [11] Yoshiyuki Fujikawa, Hong Li, Xie Yue, C. V. Aravinda, Amar Prabhu G. и Lin Meng. «Recognition of Oracle Bone Inscriptions by using Two Deep Learning Models». B: *International Journal of Digital Humanities* 5.2 (2023), с. 65—79. DOI: [10.1007/s42803-022-00044-9](https://doi.org/10.1007/s42803-022-00044-9).
- [12] Haisu Guan, Huanxin Yang, Xinyu Wang, Shengwei Han, Yongge Liu, Lianwen Jin, Xiang Bai и Yuliang Liu. «Deciphering Oracle Bone Language with Diffusion Models». B: *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*. Bangkok, Thailand: ACL, 2024, с. 15554—15567. arXiv: [2406.00684](https://arxiv.org/abs/2406.00684).
- [13] Mehmet Oğuz Derin и Erdem Uçar. «Augmenting parametric data synthesis with 3D simulation for OCR on Old Turkic runiform inscriptions: A case study of the Kül Tegin inscription». B: *Journal of Old Turkic Studies* 8.2 (2024), с. 278—301. DOI: [10.35236/jots.1501797](https://doi.org/10.35236/jots.1501797).
- [14] Marlen Mukashev и Ualsher Tukeyev. «Study Neural Model for Recognition of Ancient Turkic Orkhon Runes». B: *Advances in Computational Collective Intelligence. ICCCI 2024. Communications in Computer and Information Science, vol. 2166*. Cham: Springer, 2024, с. 221—233. DOI: [10.1007/978-3-031-70259-4_17](https://doi.org/10.1007/978-3-031-70259-4_17).
- [15] Seyed Hamid Taheri, Houman Kosarirad, Ignasi Adrover Gallego и Niloofar Taheri. «A Deep Learning Based Optical Character Recognition Model for Old Turkic». B: *EAI Endorsed Transactions on AI and Robotics* 4 (2025). DOI: [10.4108/airo.8460](https://doi.org/10.4108/airo.8460).
- [16] Théophile Rageau, Laurence Likforman-Sulem, Attilio Fiandrotti, Victoria Eyharabide, Béatrice Caseau и Jean-Claude Cheynet. «Character recognition in Byzantine seals with deep neural networks». B: *Digital Applications in Archaeology and Cultural Heritage* 37 (2025), e00403. DOI: [10.1016/j.daach.2025.e00403](https://doi.org/10.1016/j.daach.2025.e00403).
- [17] Прокопьев Д.С. «Автоматический перевод и распознавание рунических текстов». Выпускная квалификационная работа. «Московский физико-технический институт (национальный исследовательский университет)», 2026.

- [18] Прокопьев Д.С. *Runic AI: Machine Translation for Runic Inscriptions*. https://github.com/dimapchik/runic_ai. репозиторий с кодом и данными; (дата обращения: 01.06.2026). 2026.
- [19] Lei Kang, Pau Riba, Marçal Rusiñol, Alicia Fornés и Mauricio Villegas. «Pay Attention to What You Read: Non-recurrent Handwritten Text-Line Recognition». В: *Pattern Recognition* 129 (2022), с. 108766.
- [20] Daniel Hernandez Diaz, Siyang Qin, Reeve Ingle, Yasuhisa Fujii и Alessandro Bissacco. *Rethinking Text Line Recognition Models*. 2021. arXiv: [2104.07787](https://arxiv.org/abs/2104.07787).
- [21] Denis Coquenot, Clément Chatelain и Thierry Paquet. «DAN: a Segmentation-free Document Attention Network for Handwritten Document Recognition». В: *IEEE Transactions on Pattern Analysis and Machine Intelligence* 45.7 (2023), с. 8227—8243. DOI: [10.1109/TPAMI.2023.3235826](https://doi.org/10.1109/TPAMI.2023.3235826).
- [22] Yuting Li, Dexiong Chen, Tinglong Tang и Xi Shen. «HTR-VT: Handwritten Text Recognition with Vision Transformer». В: *Pattern Recognition* 158 (2025), с. 110967. arXiv: [2409.08573](https://arxiv.org/abs/2409.08573).
- [23] Phillip Benjamin Ströbel, Simon Clematide, Martin Volk и Tobias Hodel. «Transformer-based HTR for Historical Documents». В: *arXiv preprint*. 2022. arXiv: [2203.11008](https://arxiv.org/abs/2203.11008).
- [24] Phillip Benjamin Ströbel, Tobias Hodel, Walter Boente и Martin Volk. «The Adaptability of a Transformer-Based OCR Model for Historical Documents». В: *ICDAR 2023 Workshops. LNCS 14193*. Springer, 2023, с. 34—48.
- [25] Daniel Parres и Roberto Paredes. «Fine-Tuning Vision Encoder–Decoder Transformers for Handwriting Text Recognition on Historical Documents». В: *ICDAR 2023. LNCS 14190*. Springer, 2023, с. 253—268. DOI: [10.1007/978-3-031-41685-9_16](https://doi.org/10.1007/978-3-031-41685-9_16).
- [26] Masato Fujitake. «DTrOCR: Decoder-only Transformer for Optical Character Recognition». В: *Proceedings of WACV*. 2024. DOI: [10.1109/WACV57701.2024.00784](https://doi.org/10.1109/WACV57701.2024.00784).
- [27] Thibault Clérice, Ariane Pinche, Malamatenia Vlachou-Efstathiou и др. *CATMuS Medieval: A multilingual large-scale cross-century dataset in Latin script*. HAL-04453952. 2024.
- [28] Mohamed Ali Souibgui и др. «Text-DIAE: A Self-Supervised Degradation-Invariant Autoencoder for Text Recognition and Document Enhancement». В: *Proceedings of AAAI*. Т. 37. 2023, с. 2330—2338.
- [29] Nikolai Vogler, Brad Allen, Tom Miller и Taylor Berg-Kirkpatrick. *Lacuna Reconstruction: Self-Supervised Pre-training for Low-Resource Historical Document Transcription*. 2022. arXiv: [2112.08692](https://arxiv.org/abs/2112.08692).

- [30] Haotian Liu, Chunyuan Li, Qingyang Wu и Yong Jae Lee. «Visual Instruction Tuning (LLaVA)». В: *Proceedings of NeurIPS*. 2023.
- [31] Peng Wang и др. *Qwen2-VL: Enhancing Vision-Language Model's Perception of the World at Any Resolution*. 2024. arXiv: [2409.12191](#).
- [32] Zhe Chen и др. «InternVL: Scaling up Vision Foundation Models and Aligning for Generic Visual-Linguistic Tasks». В: *Proceedings of CVPR*. 2024. arXiv: [2312.14238](#).
- [33] Yuan Yao и др. «MiniCPM-V: A GPT-4V Level MLLM on Your Phone». В: *Nature Communications* 16 (2025). DOI: [10.1038/s41467-025-61040-5](#).
- [34] Bin Xiao и др. «Florence-2: Advancing a Unified Representation for a Variety of Vision Tasks». В: *Proceedings of CVPR*. 2024. arXiv: [2311.06242](#).
- [35] Gemini Team Google. *Gemini: A Family of Highly Capable Multimodal Models*. 2023. arXiv: [2312.11805](#).
- [36] Yuliang Liu и др. «On the Hidden Mystery of OCR in Large Multimodal Models (OCRBench)». В: *Science China Information Sciences* (2024). arXiv: [2305.07895](#).
- [37] Ling Fu, Jiang Kuang, Zhe Song и др. *OCRBench v2: An Improved Benchmark for Evaluating Large Multimodal Models on Visual Text Localization and Reasoning*. 2025. arXiv: [2501.00321](#).
- [38] Charlie Cowen-Breen, Creston Brooks, Barbara Graziosi и Johannes Haubold. *Logion: Machine Learning for Greek Philology*. 2024. arXiv: [2409.13870](#).
- [39] Glenn Jocher и др. *YOLOv5 / YOLOv8 / YOLO11*. Ultralytics. <https://github.com/ultralytics>. 2020.
- [40] Chien-Yao Wang, I-Hau Yeh и Hong-Yuan Mark Liao. «YOLOv9: Learning What You Want to Learn Using Programmable Gradient Information». В: *Proceedings of ECCV*. 2024. arXiv: [2402.13616](#).
- [41] Youngmin Baek, Bado Lee, Dongyoon Han, Sangdoo Yun и Hwalsuk Lee. «Character Region Awareness for Text Detection (CRAFT)». В: *Proceedings of CVPR*. 2019.
- [42] Minghui Liao, Zhaoyi Wan, Cong Yao, Kai Chen и Xiang Bai. «Real-time Scene Text Detection with Differentiable Binarization (DBNet)». В: *Proceedings of AAAI*. 2020. arXiv: [1911.08947](#).
- [43] Xingxing Xie, Gong Cheng, Jiabao Wang, Xiwen Yao и Junwei Han. «Oriented R-CNN for Object Detection». В: *Proceedings of ICCV*. 2021. arXiv: [2108.05699](#).

- [44] Jiaming Han, Jian Ding, Nan Xue и Gui-Song Xia. «ReDet: A Rotation-equivariant Detector for Aerial Object Detection». В: *Proceedings of CVPR*. 2021. arXiv: [2103.07733](https://arxiv.org/abs/2103.07733).
- [45] Darko Brodić и др. «Recent advances in text line segmentation and baseline detection in historical document images». В: *International Journal on Document Analysis and Recognition* (2025). DOI: [10.1007/s10032-025-00526-w](https://doi.org/10.1007/s10032-025-00526-w).
- [46] Sergey Lomov, Anton Stepanov и Dmitry Kropotov. «YOLO-HTR: Page-Level Recognition of Historical Handwritten Document Collections». В: *Proceedings of AIST*. Springer, 2025.
- [47] RuneS-DB. *Runic Writing in the Germanic Languages: project portal*. Akademie der Wissenschaften zu Göttingen / Kiel. <https://www.runesdb.eu/> (дата обращения: 15.05.2026). 2026.
- [48] Marco Bianchi. *Samnordisk runtextdatabas / Scandinavian Runic-text Database*. Uppsala University. <http://www.nordiska.uu.se/forskn/samnord.htm> (дата обращения: 15.05.2026). 2026.
- [49] Magnus Källström. «Corpus Editions of Swedish Runic Inscriptions». В: *Futhark: International Journal of Runic Studies* 12 (2022), с. 7—27.
- [50] Lisbeth M. Imer, Laila Kitzler Åhfeldt и Henrik Zedig. «A lady of leadership: 3D-scanning of runestones in search of Queen Thyra and the Jelling Dynasty». В: *Antiquity* 97.395 (2023), с. 1262—1278. DOI: [10.15184/aqy.2023.108](https://doi.org/10.15184/aqy.2023.108).
- [51] Tobias Dencker, Pablo Klinkisch, Stefan M. Maul и Björn Ommer. «Deep learning of cuneiform sign detection with weak supervision using transliteration alignment». В: *PLOS ONE* 15.12 (2020), e0243039. DOI: [10.1371/journal.pone.0243039](https://doi.org/10.1371/journal.pone.0243039).
- [52] Bartosz Bogacz и Hubert Mara. «Digital Assyriology — Advances in Visual Cuneiform Analysis». В: *ACM Journal on Computing and Cultural Heritage* 15.2 (2022), с. 17.
- [53] Robin Rombach, Andreas Blattmann, Dominik Lorenz, Patrick Esser и Björn Ommer. «High-Resolution Image Synthesis with Latent Diffusion Models». В: *Proceedings of CVPR*. 2022, с. 10684—10695.
- [54] Lvmin Zhang, Anyi Rao и Maneesh Agrawala. «Adding Conditional Control to Text-to-Image Diffusion Models (ControlNet)». В: *Proceedings of ICCV*. 2023, с. 3836—3847. arXiv: [2302.05543](https://arxiv.org/abs/2302.05543).
- [55] Sharon Fogel, Hadar Averbuch-Elor, Sarel Cohen, Shai Mazor и Roei Litman. «ScrabbleGAN: Semi-Supervised Varying Length Handwritten Text Generation». В: *Proceedings of CVPR*. 2020, с. 4324—4333.

- [56] Tineke Looijenga. *Texts and Contexts of the Oldest Runic Inscriptions*. The Northern World, vol. 4. Leiden; Boston: Brill, 2003. ISBN: 9004123962.
- [57] Klaus Düwel. *Runenkunde*. 4-е изд. Stuttgart: J. B. Metzler, 2008.
- [58] Michael P. Barnes. *Runes: A Handbook*. Woodbridge: The Boydell Press, 2012. ISBN: 9781843837787.
- [59] Wolfgang Krause и Herbert Jankuhn. *Die Runeninschriften im älteren Futhark*. Göttingen: Vandenhoeck & Ruprecht, 1966.
- [60] Elmer H. Antonsen. *A Concise Grammar of the Older Runic Inscriptions*. Tübingen: Max Niemeyer Verlag, 1975.
- [61] Michael Schulte. «The Rise of the Younger Futhark: The Invisible Hand of Change». В: т. 60/61. 2011, с. 45—68.
- [62] Marie Stoklund. «The Danish Inscriptions of the Early Viking Age and the Transition to the Younger Futhark». В: 2010.
- [63] Terje Spurkland. *Norwegian Runes and Runic Inscriptions*. Woodbridge: The Boydell Press, 2005. ISBN: 1843831864.
- [64] R. I. Page. *An Introduction to English Runes*. 2-е изд. Woodbridge: The Boydell Press, 1999.
- [65] David N. Parsons. *Recasting the Runes: The Reform of the Anglo-Saxon Futhorc*. Uppsala: Institutionen för nordiska språk, Uppsala universitet, 1999.
- [66] Alfred Bammesberger. *Old English Runes and their Continental Background*. Heidelberg: Carl Winter, 1991.
- [67] Graeme Earl и др. *Reflectance Transformation Imaging and raking light for epigraphy*. 2010.
- [68] Calia и др. *Imaging conditions for stone inscription documentation*. требует финальной сверки. 2023.
- [69] Uppsala University. *Samnordisk runtextdatabas (Rundata): project history and versions*. Department of Scandinavian Languages. 2024.
- [70] Riksantikvarieämbetet. *Söktjänsten Runor*. <https://app.raa.se/open/runor/>. 2024.
- [71] Henrik Williams, Marco Bianchi и Christiane Zimmermann. «Corpus Editions of Runic Inscriptions in Supranational Databases». В: *Futhark: International Journal of Runic Studies* 12 (2022). опубликовано 2022, том за 2021, с. 117—135.
- [72] Klaus Düwel, Edith Marold и Christiane Zimmermann. «Das Projekt «Runische Schriftlichkeit in den germanischen Sprachen» (RuneS)». В: (2011).

- [73] Nationalmuseet Danmark и Københavns Universitet. *Danske Runeindskrifter*. <https://runer.ku.dk>. 2024.
- [74] Kulturhistorisk museum, Universitetet i Oslo. *Runic Archives (Runearkivet)*. 2024.
- [75] Europeana Foundation. *Europeana REST API and aggregation services*. <https://pro.europeana.eu>. 2024.
- [76] Unicode Consortium. *Runic. The Unicode Standard, Range U+16A0–U+16FF*. <https://www.unicode.org/charts/PDF/U16A0.pdf>. введён в Unicode 3.0 (1999); 8 знаков добавлены в 7.0 (2014).
- [77] Judith Jesch. *Runic notation conventions in the Scandinavian Runic-text Database*. 2013.
- [78] Magnus Källström. *Mästare och minnesmärken: Studier kring vikingatida runristare och skriftmiljöer i Norden*. Stockholm Studies in Scandinavian Philology, N.S. 43. Stockholm: Almqvist & Wiksell International, 2007.
- [79] Henrik Williams. «Read What’s There: Interpreting Runestone Inscriptions». В: *Futhark: International Journal of Runic Studies* 1 (2010), с. 27—39.
- [80] Patrick Esser, Sumith Kulal, Andreas Blattmann, Rahim Entezari, Jonas Müller, Harry Saini, Yam Levi, Dominik Lorenz, Axel Sauer, Frederic Boesel, Dustin Podell, Tim Dockhorn, Zion English, Kyle Lacey, Alex Goodwin, Yannik Marek и Robin Rombach. «Scaling Rectified Flow Transformers for High-Resolution Image Synthesis». В: *Proceedings of the 41st International Conference on Machine Learning*. Т. 235. Proceedings of Machine Learning Research. PMLR, 2024, с. 12606—12633.

А Пример секции аппендикса